

Universidad de Castilla-La Mancha

Escuela Superior de Ingeniería Informática de Albacete

Escuela Superior de Informática de Ciudad Real

Trabajo Fin de Máster

Máster Universitario en Ingeniería Informática

Enfoques de análisis clúster y aprendizaje automático para la caracterización de jugadores de balonmano de alto rendimiento

Javier Senabre Urrea

Julio, 2026

Escuela Superior de Ingeniería Informática Albacete

Escuela Superior de Informática

TRABAJO FIN DE MÁSTER

Máster Universitario en Ingeniería Informática

Enfoques de análisis clúster y aprendizaje automático para la caracterización de jugadores de balonmano de alto rendimiento

Autor: Javier Senabre Urrea

Director: Eusebio Angulo Sánchez-Herrera

Codirector: José Ángel Martín Baos

UCLM Universidad Castilla-La Mancha

Julio, 2026

A mis padres

Declaración de autoría

Yo, Javier Senabre Urrea, con DNI 49432922B, declaro que soy el único autor del trabajo fin de máster titulado ”Enfoques de análisis clúster y aprendizaje automático para la caracterización de jugadores de balonmano de alto rendimiento”, que el citado trabajo no infringe las leyes en vigor sobre propiedad intelectual, y que todo el material no original contenido en dicho trabajo está apropiadamente atribuido a sus legítimos autores.

Albacete, a 6 de Julio de 2026

Fdo.: Javier Senabre Urrea

Resumen

El balonmano de alto rendimiento genera una gran cantidad de información que hasta ahora se ha explotado de forma manual por entrenadores y analistas. El acceso a datos de competiciones oficiales permite aplicar técnicas de computación avanzadas para obtener caracterizaciones objetivas de los jugadores. Este Trabajo Fin de Máster propone una metodología basada en Análisis Clúster y Aprendizaje Automático para caracterizar a jugadores de balonmano a partir de datos reales de la *European Handball Federation* (*EHF*).

Los datos utilizados proceden de los campeonatos europeos de 2024, obtenidos a través de la *API* oficial de la *EHF*. Para cada jugador se dispone de muchas variables que recogen en cada partido sobre todas las acciones realizadas en el campo, como lanzamientos, asistencias, faltas o tiempo de juego.

El objetivo general es desarrollar esta metodología para caracterizar a jugadores de alto rendimiento con datos reales de la *EHF*. De forma específica, se busca procesar y depurar los datos de los campeonatos, diseñar una metodología de Análisis Clúster y Aprendizaje Automático para agrupar a los jugadores según su rendimiento, caracterizarlos según su posición en el campo tanto en categoría masculina como femenina, y comparar los resultados obtenidos entre ambas modalidades. Para lograrlo, se combina el análisis clúster mediante *K-Means*, *Ward* jerárquico y *DBSCAN* con modelos de clasificación supervisada como *Random Forest*, *XGBoost*, *SVM* y *MLP*, capaces de predecir la posición de juego a partir de las estadísticas. Además, se emplea la técnica *SHAP* para identificar las variables más influyentes en cada posición y comparar los resultados entre ambas modalidades.

En conjunto, este trabajo sienta una base metodológica para analizar de forma objetiva el rendimiento en balonmano, con aplicación posible en scouting, apoyo a decisiones técnicas y seguimiento individual de jugadores.

Agradecimientos

Primero, a mis padres por su apoyo, cariño y por todos los valores y enseñanzas que me han transmitido a lo largo de mi vida. Gracias por ser los mejores padres Celes y Reme.

También, quiero agradecer a mi hermana Lucia por conseguir sacarme una sonrisa y alegrarme cada vez que nos reunimos. A mi tía Maryasun y a mis primas, María, Alejandra y Ana por su cariño, su apoyo y por todos los buenos momentos compartidos en familia.

A mi amigo Paco por siempre darme ánimos y apoyo en esas tardes/noches de juegos que han servido para desconectar y recargar energías. A mis amigos del pueblo, Fernando, Juan Carlos y Cristian, por su amistad, su apoyo y por todos los momentos vividos a lo largo de estos años, especialmente durante aquellas expediciones al campo para grabar animales salvajes y las quedadas de las tardes.

Quiero agradecer especialmente a mis tutores, Eusebio Angulo Sánchez-Herrera y José Ángel Martín Baos, por su dedicación, orientación y disponibilidad durante el desarrollo de este Trabajo de Fin de Máster. Gracias por resolver todas mis dudas, por vuestra paciencia y por ayudarme a superar los problemas que fueron surgiendo durante el proyecto.

Y, por último, pero no por ello menos importante, quiero dar las gracias a mis primos, Alejandro y Francisco, especialmente a Alejandro, por todas esas tardes de sábado llenas de risas y buenos momentos que siempre recordaré.

A todos vosotros, gracias.

Índice general

1 Introducción 1

1.1 Motivación y contexto 1

1.2 Estructura del documento 3

2 Objetivos 5

2.1 Objetivo general 5

2.2 Objetivos específicos 5

3 Estado del Arte 9

3.1 Aprendizaje automático 9

3.2 Análisis clúster 10

3.2.1 Evaluación de resultados de clustering 12

3.3 Modelos de aprendizaje automático 12

3.3.1 Modelos supervisados para clasificación y predicción 13

3.3.2 Evaluación de los modelos supervisados 13

3.3.3 Random Forest y XGboost 16

3.3.4 Máquinas de vectores soporte (SVM) 16

3.3.5 Redes neuronales 17

3.3.6 Interpretabilidad de modelos de aprendizaje automático (SHAP) 18

3.4 Balonmano 18

3.5 Aprendizaje automático aplicado al deporte 20

3.5.1 Análisis cluster en el deporte 20

3.5.2 Análisis clúster aplicado al balonmano 23

3.5.3 Aplicaciones de aprendizaje automático en deportes de equipo 26

3.5.4 Aprendizaje supervisado aplicado al balonmano 28

4 Metodología 31

4.1 Introducción 31

4.2 Planificación de *sprints* 32

5 Resultados 35

5.1 *Sprint* 1: Preprocesamiento 35

5.1.1 Obtención de los datos 35

5.1.2 Tratamiento de los datos y selección de variables 36

5.1.3 Análisis exploratorio de los datos 38

5.1.4 Conclusión de la exploración 43

5.2 Sprint 2: Análisis *Clustering* 44

5.2.1 Introducción 44

5.2.2 K-means 44

5.2.3 Clustering jerárquico Ward 46

5.2.4 DBSCAN 46

5.2.5 Escalado de las variables 46

5.2.6 Reducción de dimensionalidad: PCA 48

5.2.7 Análisis del impacto de la variable Time 48

5.2.8 Generación de los resultados 48

5.2.9 Resultados de K-Means y Clustering jerárquico Ward 49

5.2.10 Resultados del agrupamiento por clase 53

5.3 Sprint 3: Clasificación y relevancia de variables 56

5.3.1 Introducción 56

5.3.2 Configuración inicial del experimento 57

5.3.3 Ajuste de hiperparámetros 57

5.3.4 Resultados de los experimentos 60

5.3.5 Importancia de las variables 66

5.4 Sprint 4: Comparación entre balonmano masculino y femenino 69

5.4.1 Comparación de resultados 69

5.4.2 Comparación de importancia de variables SHAP 72

5.4.3 Conclusiones de la comparación 74

6 Conclusión y trabajo futuro 75

6.1 Objetivos alcanzados 75

6.2 Competencias adquiridas 76

6.3 Trabajo futuro 77

A Anexo 1 79

A.1 Software del proyecto 79

A.1.1 Python 79

A.1.2 Jupyter Notebook 79

A.1.3 Visual Studio Code 79

A.1.4 Librerías de Python 79

A.1.5 Microsoft Teams 80

A.2 Hardware del proyecto 80

Referencia bibliográfica 85

Índice de figuras

3.1 Ejemplo de funcionamiento de *K-means* [1] 11
3.2 Matriz de confusión binaria [2] 14
3.3 Esquema de la validación cruzada [3] 15
3.4 Separación del hiperplano de las clases[4] 17
3.5 Campo de balonmano [5] 19

4.1 Diagrama de *Gantt* de la planificación del proyecto 32

5.1 Distribución de jugadores de campo por posición 39
5.2 Estadísticos descriptivos 40
5.3 Matriz de correlación 41
5.4 Proporción de ceros y asimetría por variable 42
5.5 Comparativa entre *clusters* del algoritmo *K-Means* y posiciones reales . . 45
5.6 Comparativa entre *clusters* del algoritmo *DBSCAN* y posiciones reales . . 47
5.7 Comparativa del coeficiente de Silhouette y elbow para *K-Means* y *Ward* en los tres experimentos (*PCA2*, *PCA3* y *RAW*) 50
5.8 Atributos de los *clusters* para $k = 4$. 52
5.9 Matrices de confusión de los cuatro modelos (6 posiciones) 63
5.10 Matrices de confusión de los cuatro modelos (4 posiciones) 65
5.11 Importancia global de las variables (*Random Forest*) del torneo masculino 67
5.12 Importancia de variables por clase (*Random Forest*) del torneo masculino 68
5.13 Matrices de confusión de los cuatro modelos en la modalidad femenina (4 posiciones) 71
5.14 Importancia global de las variables del torneo femenino (*MLP*) 72
5.15 Importancia de variables por clase del torneo femenino (*MLP*) 73

Índice de tablas

3.1 Resumen de algoritmos de *clustering* y técnicas relacionadas aplicados en estudios de otros deportes 23
3.2 Resumen de algoritmos de clustering en estudios de balonmano 25
3.3 Resumen de algoritmos de clasificación y técnicas relacionadas 27
3.4 Resumen de algoritmos de clasificación y técnicas relacionadas en estudios de balonmano 29

5.1 Jugadores del primer *cluster* en la posición central. 54
5.2 Hiperparámetros para *Random Forest* 58
5.3 Hiperparámetros para *XGBoost* 59
5.4 Hiperparámetros para *SVM* 59
5.5 Espacio de búsqueda de hiperparámetros para la red neuronal *MLP* . . . 60
5.6 Mejores hiperparámetros por modelo del experimento 1 Masculino 2024 61
5.7 Mejores hiperparámetros por modelo del experimento 2 Masculino 2024 61
5.8 Métricas globales del experimento 1 62
5.9 Métricas globales del experimento 2 64
5.10 Comparativa de métricas entre torneos 70
5.11 Mejores hiperparámetros por modelo del experimento 2 para el torneo femenino 71

A.1 Librerías de Python utilizadas en el desarrollo del proyecto 80
A.2 Especificaciones del equipo utilizado en el proyecto. 80

Índice de algoritmos

5.1 Cálculo de lanzamientos fallados por tipo 37

1. Introducción

1.1. Motivación y contexto

El análisis del rendimiento deportivo ha experimentado una transformación profunda en los últimos años gracias al avance de las técnicas de análisis de datos y aprendizaje automático. Lo que antes dependía exclusivamente del criterio subjetivo de entrenadores y analistas, hoy puede complementarse con metodologías objetivas capaces de extraer patrones complejos a partir de volúmenes de estadísticas reales de competición. En deportes de equipo como el balonmano, donde cada jugador ocupa un rol en el campo bien definido con responsabilidades físicas y técnicas, esta capacidad de análisis resulta especialmente valiosa.

La *European Handball Federation* (*EHF*) recopila una gran cantidad de información estadística durante los campeonatos de Europa. Torneos que reúnen a jugadores y selecciones del continente y que constituyen una fuente de datos muy fiables para el análisis del rendimiento. Sin embargo, el elevado número de variables disponibles dificulta considerablemente la extracción manual de patrones relevantes. Identificar qué estadísticas caracterizan a cada posición, qué jugadores destacan dentro de su rol, qué agrupaciones se pueden crear por el rendimiento o posición de los jugadores o qué diferencias existen entre el juego masculino y el femenino son preguntas que pueden responderse más fácilmente con el apoyo de técnicas avanzadas de análisis de datos.

En este contexto, trabajos previos han demostrado que las estadísticas de competición permiten identificar perfiles de rendimiento en balonmano. Como el estudio *A feature-weighting approach using metaheuristic algorithms to evaluate the performance of handball goalkeepers* [6] donde han estudiado la importancia de las acciones individuales de los jugadores para caracterizar su rendimiento, y en trabajos posteriores como *Bio-inspired*

algorithms for the characterization of excellent performance in handball players: A data-driven methodology [7] han propuesto metodologías basadas en algoritmos bioinspirados para optimizar el peso de cada variable en función de la posición. Estos estudios ponen de manifiesto que no todas las estadísticas tienen el mismo valor discriminatorio y que la selección adecuada de variables es crítico para obtener buenos resultados. Este hecho constituye el punto de partida de este TFM, que busca extender esas ideas incorporando técnicas de clustering y clasificación supervisada sobre datos reales del torneo europeo.

El análisis clúster y los modelos de aprendizaje automático supervisado ofrecen herramientas complementarias para abordar este problema desde dos punto de vista diferentes. Por un lado, el clustering permite descubrir agrupaciones naturales en los datos sin utilizar información sobre las posiciones reales de los jugadores, mostrando si las estadísticas de competición son suficientes para estructurar de forma coherente los jugadores. Por otro lado, los modelos supervisados permiten predecir la posición de un jugador a partir de sus estadísticas, e identificar mediante técnicas de interpretabilidad qué variables son las más determinantes en cada caso.

En este trabajo, se aplicarán y analizarán estas técnicas en los torneos masculino y femenino del campeonato europeo de balonmano de 2024. Más específicamente, se realiza una comparativa de ambos torneos en modelos de aprendizaje automático para conocer las diferencias más notables para determinar la posición de uno u otro. La categoría femenina ha recibido históricamente menos atención en el análisis de rendimiento en balonmano, por lo que estudiar sus patrones estadísticos y compararlos con los del torneo masculino tiene valor tanto científico como práctico. Determinar si existen diferencias en las variables que mejor caracterizan a cada rol, puede tener implicaciones directas para planificación de entrenamientos o selección de jugadores.

La utilidad de este tipo de análisis va más allá del contexto académico, ya que un sistema capaz de agrupar automáticamente a los jugadores por perfil de rendimiento o de clasificar su posición a partir de las estadísticas podría ser una herramienta de gran valor para los cuerpos técnicos, tanto para evaluar a sus propios jugadores como para el análisis de rivales. En este trabajo se plantea precisamente esa posibilidad, demostrando que los modelos entrenados sobre datos reales del torneo europeo son capaces de identificar los perfiles de élite dentro de cada posición con un grado de coincidencia alto respecto a las nominaciones oficiales de la *EHF*.

1.2. Estructura del documento

El documento se organiza en los siguientes capítulos:

- **Capítulo 2. Objetivos:** define el objetivo general del trabajo y lo desglosa en cuatro objetivos específicos que guían el desarrollo de cada *sprint*: el preprocesamiento de los datos, el diseño de los experimentos de *clustering*, la construcción de modelos de clasificación supervisada y la comparativa entre categorías.
- **Capítulo 3. Estado del arte:** revisa la literatura científica relacionada con el problema abordado. Se introducen los fundamentos del aprendizaje automático y del análisis clúster, se describen los modelos supervisados empleados en el trabajo (*Random Forest*, *XGBoost*, *SVM* y *MLP*) y las técnicas de interpretabilidad basadas en *SHAP*. Además, se recogen estudios previos que aplican estas metodologías en distintos deportes de equipo y, con mayor detalle, en balonmano, sirviendo de referencia para las decisiones metodológicas adoptadas en este trabajo.
- **Capítulo 4. Metodología:** describe la metodología *Scrum unipersonal* adoptada para organizar el trabajo, justificando su idoneidad para un proyecto de ciencia de datos de naturaleza iterativa. Se detalla la planificación de los cuatro *sprints*, sus objetivos concretos y los entregables asociados a cada uno.
- **Capítulo 5. Resultados:** presenta y analiza los resultados obtenidos en cada *sprint*. El *Sprint 1* describe el proceso de obtención de los datos desde la *API* de la *EHF*, el tratamiento y selección de variables y el análisis exploratorio del conjunto de datos. El *Sprint 2* recoge los experimentos de agrupamiento no supervisado con K-Means, Ward y DBSCAN bajo tres configuraciones de preprocesamiento, así como un análisis secundario de clustering por posición para identificar perfiles de élite. El *Sprint 3* presenta los experimentos de clasificación supervisada con *Random Forest*, *XGBoost*, *SVM* y *MLP*, el ajuste de hiperparámetros mediante *GridSearchCV* y el análisis de importancia de variables con *SHAP* a nivel global y por clase. El *Sprint 4* extiende el análisis al torneo femenino y realiza una comparativa de los resultados obtenidos en ambas categorías.
- **Capítulo 6. Conclusiones y trabajo futuro:** resume las principales aportaciones del trabajo, las competencias del trabajo fin de máster adquiridas y propone posibles líneas de trabajo futuras que podrían ampliar o mejorar la metodología desarrollada.

2. Objetivos

2.1. Objetivo general

El objetivo de este trabajo fin de máster es desarrollar una metodología basada en técnicas de análisis clúster y aprendizaje automático que permita la caracterización de jugadores de balonmano de alto rendimiento, utilizando datos reales proporcionados por la *European Handball Federation* (*EHF*) correspondientes a varias ediciones recientes de los Campeonatos de Europa. La metodología tratará de establecer agrupaciones de jugadores en función de sus estadísticas y posición en el campo, sin utilizar información sobre sus posiciones reales. También, se construirán modelos de clasificación supervisada que permitan identificar las variables estadísticas más determinantes en cada grupo y, mediante técnicas de interpretabilidad, explicar las diferencias encontradas. El análisis se llevará a cabo de forma paralela para la categoría masculina y femenina, con el fin de determinar si los patrones de rendimiento difieren en función del género.

2.2. Objetivos específicos

Para alcanzar el objetivo general planteado, se establecen los siguientes objetivos específicos:

1. **Procesar y depurar los datos proporcionados por la *European Handball Federation* (*EHF*)** correspondientes a las cuatro últimas ediciones de los Campeonatos de Europa de balonmano, garantizando su calidad y consistencia para el análisis. Se realizarán estas tareas para completar este objetivo:

- Recopilación e integración de los datos estadísticos de los campeonatos europeos de balonmano masculino y femenino de 2024.
- Selección de las variables con suficiente frecuencia de aparición y con mayor relevancia e incidencia en el rendimiento de los jugadores, descartando aquellas con escasa representatividad o no pertinentes para el estudio.
- Identificación y tratamiento de valores nulos, *outliers* y inconsistentes.
- Estandarización de las variables para garantizar la comparabilidad entre jugadores y ediciones.
- Análisis exploratorio de los datos para comprender su estructura y distribución antes de aplicar los modelos.

2. **Diseñar una metodología basada en técnicas de Análisis Clúster y Aprendizaje Automático** que permita agrupar a los jugadores según sus características de rendimiento. Para conseguirlo, se realizarán estas tareas:

   - Selección y justificación de los algoritmos de *clustering* a emplear, entre ellos *K-means*, *clustering jerárquico Ward* y *DBSCAN*.
   - Evaluación de la calidad de las agrupaciones obtenidas mediante métricas como *Silhouette* y *elbow*.
   - Análisis e interpretación de los clústeres resultantes respecto a las variables estadísticas que los definen.

3. **Caracterizar los perfiles de jugadores en función de su posición en el campo**, considerando tanto la categoría masculina como la femenina. Para lograrlo, se realizarán estas tareas:

   - Entrenamiento y comparación de distintos clasificadores, incluyendo *Random Forest*, *XGBoost*, *SVM* (*Support Vector Machine*) y *MLP* (Red neuronal simple).
   - Ajuste de hiperparámetros mediante validación cruzada para garantizar la robustez de los modelos.
   - Aplicación de técnicas de interpretabilidad basadas en valores *SHAP* para identificar las variables más determinantes en la caracterización de cada perfil.

4. **Realizar un análisis comparativo entre el balonmano masculino y el femenino** a partir de los resultados obtenidos en el proceso de agrupamiento. Para conseguirlo, se realizarán estas tareas:

- Aplicación de la misma metodología de forma independiente a los datos de la categoría masculina y femenina.
- Comparación de los resultados de importancia de las variables en el modelo de clasificación.
- Extracción de conclusiones sobre las diferencias y similitudes entre ambas categorías a partir de los resultados de los modelos supervisados.

3. Estado del Arte

3.1. Aprendizaje automático

El aprendizaje automático es una rama de la inteligencia artificial que busca que un programa aprenda de un conjunto de datos, identificando patrones con los que realizar predicciones sobre nuevas observaciones. A diferencia del paradigma de programación clásica, donde a partir de datos y reglas se obtienen salidas, el aprendizaje automático utiliza los datos y sus salidas para descubrir las reglas subyacentes [8].

Este enfoque se divide en tres paradigmas principales que difieren por la naturaleza de los datos disponibles durante el entrenamiento y en el tipo de problema que cada uno está diseñado para resolver [9]:

1. **Aprendizaje supervisado:** el conjunto de datos está etiquetado con una variable objetivo que se corresponde con la salida del problema. Gracias a esa variable, el modelo aprende a relacionar una serie de datos (entradas) con determinadas salidas, permitiendo generar nuevas salidas a partir datos nuevos. Es el paradigma empleado en tareas de clasificación y regresión. Un ejemplo es la clasificación de los jugadores por posición que se realiza más adelante, ya que se conoce la posición real de los jugadores.

2. **Aprendizaje no supervisado:** los datos no disponen de etiquetas (no se conoce la variable objetivo). El algoritmo debe aprender por sí solo la estructura del conjunto de datos para generar nuevas salidas, identificando patrones o agrupaciones. Es el paradigma en el que se enmarca el análisis clúster. Un ejemplo es agrupar jugadores por su estilo de juego o rendimiento.

3. **Aprendizaje por refuerzo:** el algoritmo aprende a base de ensayo y error mediante recompensas y castigos. Los modelos aprenden estrategias para maximizar las recompensas y minimizar las penalizaciones, con el objetivo de encontrar el mejor ajuste que potencie su capacidad de decisión.

3.2. Análisis clúster

El análisis clúster es un conjunto de técnicas computacionales que permiten descubrir patrones en datos sin necesidad de disponer de etiquetas previas. Su objetivo es agrupar los elementos más similares entre sí, formando y separando por grupos [10]. Estas técnicas se encuentran dentro del aprendizaje no supervisado y han encontrado aplicación en ámbitos tan dispares como la bioinformática, la segmentación de mercados o, más recientemente, el análisis del rendimiento deportivo.

El análisis clúster esta conformado por diversos algoritmos capaces de agrupar datos muy diferentes entre sí, pero solo se detallarán los algoritmos que se utilizan en el trabajo.

K-means

El algoritmo *K-means* es uno de los métodos de *clustering* más utilizados por su simplicidad y eficacia computacional. El procedimiento parte de la elección de k centroides iniciales y asigna iterativamente cada observación al centroide más cercano según una métrica de distancia, por ejemplo, la distancia euclidiana. Tras cada asignación, los centroides se recalculan como la media de los puntos que conforman cada grupo, y el proceso se repite hasta alcanzar la convergencia, es decir, hasta que las asignaciones dejan de cambiar entre iteraciones [11]. Las iteraciones se pueden observar en la Figura 3.1.

Entre sus principales ventajas destacan la velocidad de ejecución en conjuntos de datos de gran tamaño y la facilidad de interpretación de los resultados. Sin embargo, presenta limitaciones como la necesidad de especificar k a priori, su sensibilidad a la inicialización y a la presencia de valores atípicos, y su tendencia a producir grupos de forma esférica y tamaño similar, lo que puede resultar inadecuado cuando la estructura de los datos no responde a esas características.

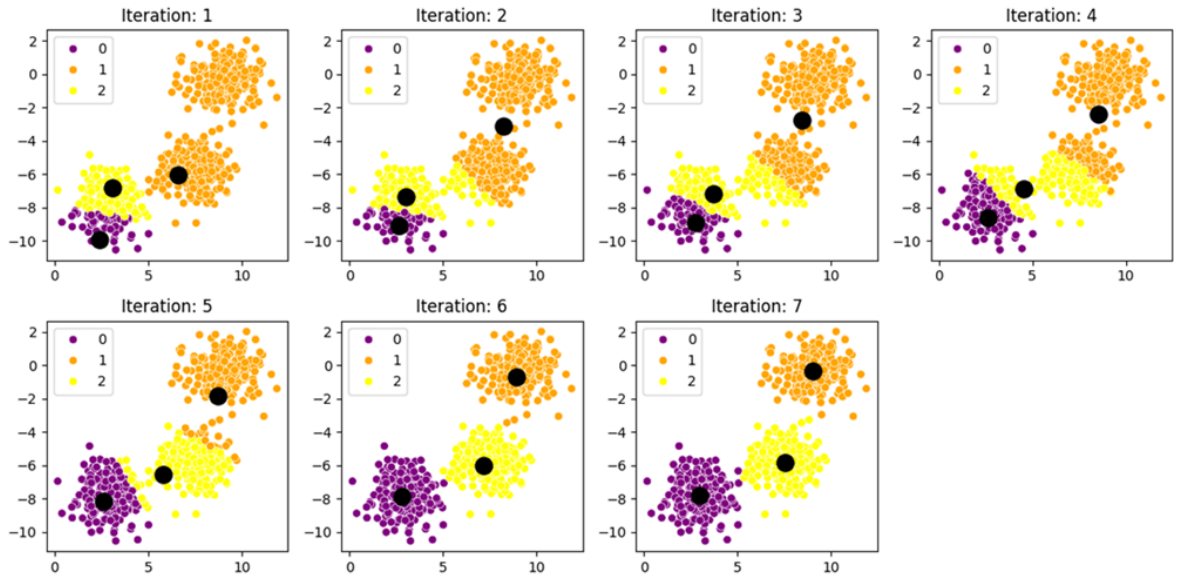


Figura 3.1: Ejemplo de funcionamiento de *K-means* [1]

Clustering jerárquico Ward

El *clustering* jerárquico construye una jerarquía de agrupaciones que puede representarse mediante un dendrograma, lo que permite seleccionar el número de clústeres a posteriori, sin necesidad de fijarlo antes de ejecutar el algoritmo. Existen dos variantes, el enfoque *aglomerativo*, que parte de cada observación como un clúster independiente y va fusionando los grupos más similares de forma sucesiva, y el *divisivo*, que opera en sentido inverso[10].

No obstante, existen diversos criterios de enlace para unir estos grupos. El método de *Ward* es el criterio de enlace más habitual y, en nuestro caso, se utiliza para los futuros experimentos junto al enfoque aglomerativo. En cada paso, fusiona los dos *clusters* cuya unión minimiza el incremento de la suma de los cuadrados de las diferencias dentro de cada *cluster*, lo que produce grupos compactos y de tamaño equilibrado. Frente a criterios alternativos como el enlace simple o el completo, el método de Ward es más robusto y genera particiones que resultan más interpretables. Su principal limitación es el coste computacional, que crece cuadráticamente con el número de observaciones, lo cual puede suponer un obstáculo en conjuntos de datos de gran escala [12].

DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) es un algoritmo de clustering basado en densidad que agrupa puntos situados en regiones de alta densidad y marca como ruido aquellos que quedan aislados en zonas de baja densidad. Este algoritmo no requiere especificar el número de clústeres a priori y es capaz de detectar grupos de forma arbitraria [13]. El algoritmo se define a partir de los hiperparámetros: ε, que es el radio que determina el vecindario de cada punto; y *MinPts*, que es el número mínimo de puntos necesarios dentro de ese radio para considerar que una región es densa. Con estos estos parámetros, los puntos se clasifican en puntos núcleo, puntos frontera y ruido.

3.2.1. Evaluación de resultados de clustering

La evaluación de la calidad de un agrupamiento (*clustering*) es una tarea más compleja que la evaluación de modelos supervisados debido a que no se tienen las etiquetas de referencia para comparar los resultados y obtener sus métricas. Con este problema, los índices de validación interna permiten cuantificar la cohesión y la separación a partir de los propios datos.

Antes de evaluar la calidad de una solución es necesario determinar cuántos clústeres resultan apropiados para los datos. El método *elbow* aborda esta cuestión para el algoritmo de *K-means* representando la inercia (la suma de las distancias al cuadrado de cada punto respecto a su centroide) en función del número de grupos k [14]. A medida que k crece, la inercia disminuye, pero lo hace cada vez con menor intensidad. Esa reducción cuando se vuelve marginal, señala el valor de k a partir del cual añadir más grupos deja de aportar información. La sencillez de la métrica la convierte en un primer criterio orientativo para escoger un k.

La métrica llamada *Silhouette* ofrece una medida directa para la coherencia de cada asignación en grupo. Para cada observación, compara la distancia media de los puntos de su propio clúster con la distancia media al *cluster* vecino más próximo, devolviendo un valor entre -1 y 1. Los valores cercanos a 1 indican que el punto está correctamente asignado y los negativos señalan una posible asignación incorrecta. La media de esta métrica permite comparar particiones con distinto número de *clusters* y, junto a la anterior, son suficientes en nuestro caso para evaluar el resultado del *clustering*.

3.3. Modelos de aprendizaje automático

3.3.1. Modelos supervisados para clasificación y predicción

El aprendizaje supervisado engloba un amplio conjunto de algoritmos cuyo objetivo es aprender la relación existente entre un conjunto de variables de entrada y una variable objetivo a partir de un conjunto de ejemplos previamente etiquetados [15]. Más específicamente, se abordará el problema de la clasificación que tiene como objetivo asignar a cada observación una de las categorías predefinidas. Existen diversos modelos y la elección del más adecuado depende de factores como el tamaño del conjunto de datos, la naturaleza de las variables, los requisitos de interpretabilidad y las restricciones computacionales del problema.

En escenarios con datos de dimensionalidad pequeña y datos estructurados como nuestro caso, los modelos basados en árboles han mostrado un rendimiento competitivo en numerosos tipos de aplicaciones, combinando su capacidad de clasificación con cierta tolerancia al sobreajuste y robustez frente a variables poco relevantes. No obstante, otros enfoques como las máquinas de vectores soporte (*SVM*) o las redes neuronales que pueden ser alternativas, y serán descritos en los apartados siguientes.

3.3.2. Evaluación de los modelos supervisados

Es muy importante realizar una metodología muy estricta para evitar que la evaluación de los modelos sean distorsionados por una fuga de datos al aprender información que no debería obtener. Principalmente, se debe dividir el conjunto de datos en dos partes, una parte para entrenarla (*train*) y otra para evaluar el modelo (*test*). También, se realiza otra subdivisión en el conjunto de entrenamiento para validar el aprendizaje del modelo. Normalmente, la distribución de estos conjuntos son 70%-85% entrenamiento y 20%-30% test, pero también deben estar estratificadas para asegurar que todas las clases definidas se encuentran en proporciones parecidas en los conjuntos de datos. Esto evita que alguna clase quede infrarrepresentada (con muy pocas observaciones de esa clase) en alguno de los conjuntos, provocando que el modelo disponga de pocos observaciones para aprender sus características o para evaluarlas correctamente, lo que dificultaría su capacidad de generalizar sobre dicha clase.

Además, existen múltiples métricas para este propósito, pero la más importante que se puede utilizar es una matriz de confusión que permite visualizar los aciertos y errores del clasificador para cada clase [16]. Existen una serie de valores fundamentales que permiten evaluar el rendimiento de un modelo de clasificación. En concreto, VP representa el número de verdaderos positivos, VN el número de verdaderos negativos, FP el número de falsos

positivos y FN el número de falsos negativos. Estos cuatro valores constituyen la matriz de confusión, cuya estructura se muestra en la Figura 3.2.



Figura 3.2: Matriz de confusión binaria [2]

En problemas de clasificación con un elevado número de clases en la variable objetivo, la matriz de confusión puede resultar difícil de interpretar debido a su tamaño y complejidad. Sin embargo, este inconveniente no se presenta en nuestro caso. Gracias a los valores anteriores, es posible obtener las métricas más habituales:

1. *Accuracy*: refleja la proporción de predicciones correctas sobre el total de predicciones realizadas.
$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}. \tag{3.1}$$
2. *Precision*: mide el porcentaje de éxito entre los casos clasificados como positivos, es decir, cuántos de los que el modelo predijo como positivos realmente lo eran.
$$\text{Precision} = \frac{VP}{VP + FP}. \tag{3.2}$$
3. *Recall*: muestra la proporción de positivos reales que el modelo fue capaz de identificar correctamente.
$$\text{Recall} = \frac{VP}{VP + FN}. \tag{3.3}$$

4. *F1-Score*: combina precisión y recall en una única medida armónica, resultando especialmente útil cuando las clases están desbalanceadas, ya que penaliza los modelos que sacrifican una métrica en favor de la otra.

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \tag{3.4}$$

Validación cruzada (*Cross-validation*)

La validación cruzada (*cross-validation*) es una técnica de evaluación que permite obtener una estimación más robusta y menos dependiente de una única partición de los datos [17]. Más específicamente, se utilizará en este trabajo la validación cruzada de k iteraciones (k-*fold cross-validation*) que consiste en dividir aleatoriamente en k subconjuntos de tamaño similar el conjunto de datos designado (entrenamiento). En cada iteración, uno de estos subconjuntos se reserva como conjunto de validación y el modelo se entrena con el resto de subconjuntos. El proceso se repite k veces de forma que cada subconjunto actúa exactamente una vez como conjunto de validación como se puede ver en la Figura 3.3.

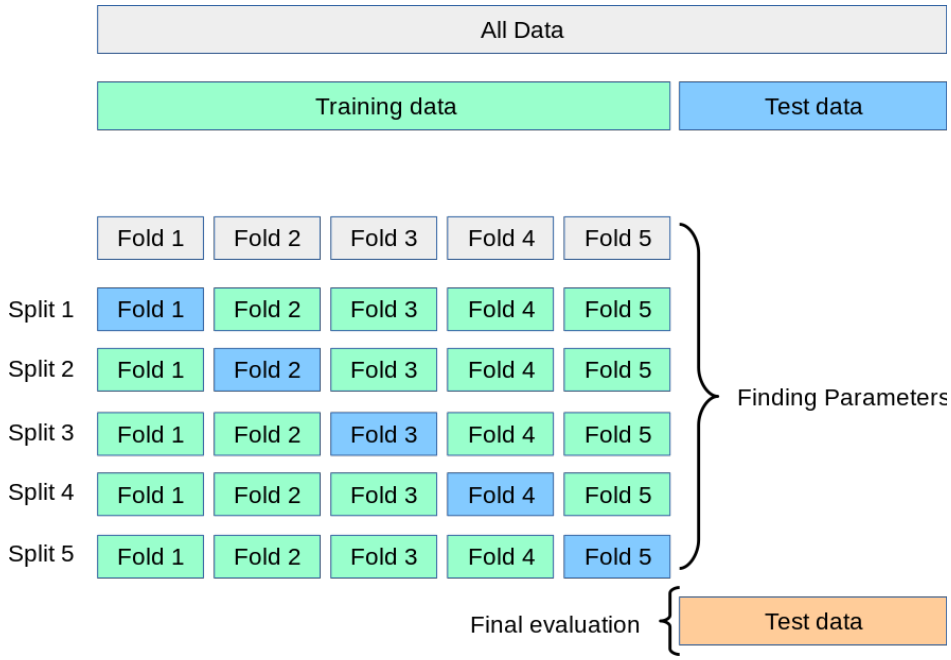


Figura 3.3: Esquema de la validación cruzada [3]

El rendimiento final del modelo se estima como la media de los resultados obtenidos en las k iteraciones, y la desviación estándar entre ellas proporciona una medida de la estabili-

dad del modelo. Normalmente, k suele estar entre 5 y 10 porque tiene buen equilibrio entre una buena estimación y coste computacional al repetir múltiples veces el entrenamiento del modelo. También, se puede aplicar una división estratificada para evitar las clases desbalanceadas.

A continuación, estudiaremos algunos de los principales modelos supervisados tradicionalmente utilizados en la literatura.

3.3.3. Random Forest y XGboost

Los *árboles de decisión* constituyen la unidad básica sobre la que se construyen los principales métodos de ensemble en aprendizaje automático. Un árbol de decisión divide recursivamente el espacio de características mediante reglas binarias que minimizan algún criterio como el índice de Gini o la entropía generando un modelo para clasificar, pero este árbol es bastante propenso al sobreajuste al crecer, es decir, se necesita restringir ese crecimiento para evitar que memorice los patrones de los datos del conjunto de entrenamiento y no sea capaz de generalizar con nuevos datos [18].

Random Forest aborda esta limitación mediante la combinación de dos mecanismos de aleatorización. El *bagging* que entrena cada árbol sobre una muestra *bootstraps*, es decir, un subconjunto generado mediante muestreo aleatorio con reemplazo a partir de los datos de entrenamiento, y la selección aleatoria de un subconjunto de variables candidatas en cada nodo de la división. Todo esto se realiza de forma paralela. Al final, la predicción se obtiene por la votación mayoritaria en clasificación o promedio en regresión sobre todos los árboles del ensemble, reduciendo el sobreajuste.

Otro modelo basado en arboles es *XGBoost* que son construidos de forma secuencial mediante *gradient boosting*. A diferencia del *bagging* del *Random Forest*, el *boosting* entrena cada árbol para corregir los errores residuales del conjunto anterior. Además, incorpora técnicas de regularización (como las penalizaciones L_1 y L_2) para controlar el sobreajuste y también es más eficiente en conjuntos de datos de gran escala. Normalmente, su rendimiento es superior al resto de modelos basados en arboles, pero depende del problema de aprendizaje automático que se enfrente [19].

3.3.4. Máquinas de vectores soporte (*SVM*)

Las máquinas de vectores soporte (*SVM* por sus siglas en inglés) son un conjunto de algoritmos de aprendizaje supervisado diseñados para tareas de clasificación binaria, aunque posteriormente extendidos a clasificación multiclase y regresión. Principalmente, consisten

en encontrar el hiperplano que separa las clases con el mayor margen posible, entendiendo el margen como la distancia entre el hiperplano y los puntos de entrenamiento más cercanos de cada clase, denominados vectores soporte [4]. Un ejemplo de esta técnica se puede observar en la Figura 3.4, dónde el modelo aprende la frontera que separa las observaciones en sus respectivas clases.

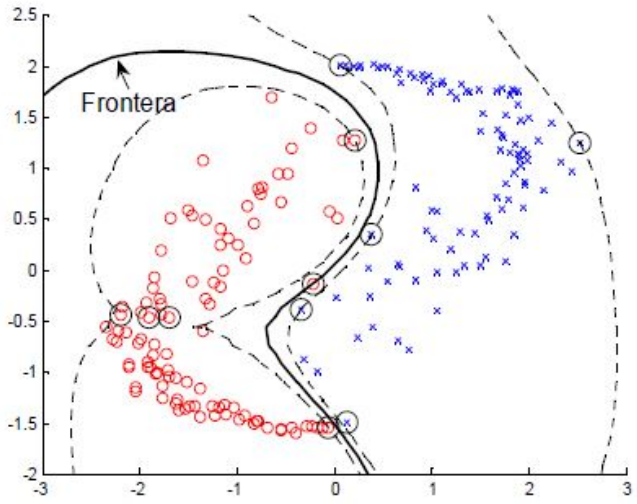


Figura 3.4: Separación del hiperplano de las clases[4]

3.3.5. Redes neuronales

Las redes neuronales artificiales son un tipo de algoritmo que intenta imitar el funcionamiento de las neuronas del cerebro humano. Están conformadas por diversas capas de nodos (neuronas artificiales) y cada neurona se conecta a otra con un peso y umbral, salvo en la capa de entrada que no tiene umbral. Si la salida de una neurona está por encima del valor umbral especificado, dicha neurona se activa y envía datos a la siguiente capa [20].

El perceptrón multicapa (MLP, *Multilayer Perceptron*) es la arquitectura de red neuronal más sencilla comúnmente empleada en tareas de clasificación sobre datos tabulares como los nuestros al ser datos estructurados. A diferencia de las redes convolucionales o recurrentes, diseñadas específicamente para imágenes o secuencias, el MLP opera mejor sobre este tipo de datos y aprende patrones no lineales mediante funciones de activación como ReLU (Rectified Linear Unit), sigmoide o tangente hiperbólica, ya que sin estas funciones solo sería capaz de aprender patrones lineales [21]. El entrenamiento se realiza mediante

el algoritmo de retropropagación (llamada *backpropagation*) que iterativamente actualiza los pesos de la red para minimizar una función de pérdida (*loss*). Una de sus ventajas es la capacidad de capturar características entre variables sin necesidad de utilizar preprocesamientos especificos o más complejos debido a que la propia red neuronal lo aprende, pero su principal limitación es la mayor necesidad de datos que otros algoritmos y la dificultad de interpretar las decisiones del modelo de forma directa.

3.3.6. Interpretabilidad de modelos de aprendizaje automático (SHAP)

A medida que los modelos de aprendizaje automático han mejorado, la necesidad de comprender e interpretar sus decisiones se ha convertido en una preocupación central. En este contexto, se crea la herramienta *SHAP* [22] (*Shapley Additive explanations*) que para cada predicción/clasificación calcula la contribución de cada variable considerando todas las posibles combinaciones de características presentes o ausentes, distribuyendo de forma equitativa el crédito predictivo entre todas ellas. El resultado es un valor por variable y por observación que indica en qué medida y en qué dirección esa característica ha empujado la predicción por encima o por debajo de la línea base del modelo.

La idea para calcular esta contribución, consiste en considerar cada variable como un "jugador" que participa en la predicción final del modelo y evaluar su aporte marginal en todas las posibles combinaciones de variables. En cada una de estas combinaciones se mide cómo varía la predicción al incluir la característica analizada y, posteriormente, se promedian dichas contribuciones. De este modo, cada variable recibe un valor *SHAP* que refleja su contribución media al resultado final, teniendo en cuenta tanto su efecto individual como sus interacciones con el resto de variables

Concretamente en los modelos basados en árboles, como *Random Forest* o *XGBoost*, esta herramienta triunfa con la variante *TreeSHAP* que permite calcular estos valores de forma más exacta y eficiente aprovechando la estructura jerárquica del modelo, haciendo su aplicación práctica en nuestros conjuntos de datos muy conveniente.

3.4. Balonmano

El balonmano es un deporte colectivo de cooperación y oposición en el que dos equipos de siete jugadores se enfrentan con el objetivo de introducir un balón en la portería contraria utilizando únicamente las manos [23]. Cada partido se disputa en dos tiempos de treinta minutos con un descanso intermedio, donde el equipo que anota más goles sobre una pis-

ta rectangular de 40 por 20 metros como la Figura 3.5 durante el partido es proclamado vencedor.

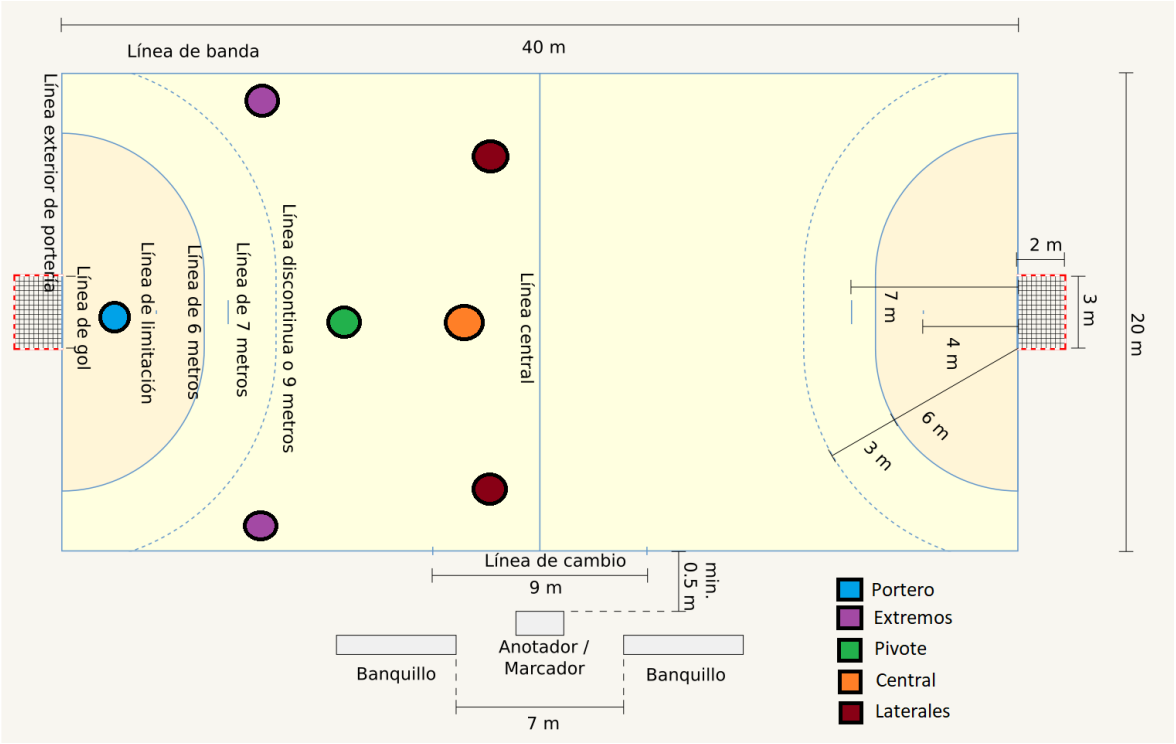


Figura 3.5: Campo de balonmano [5]

Cada jugador tiene una posición de juego que implica un conjunto de responsabilidades tácticas, físicas y técnicas, es decir, entre estas posiciones existen diversos perfiles estadísticos por las acciones.

1. **Portero (*Goalkeeper*):** es el único jugador autorizado para permanecer dentro del área de portería y el único que puede utilizar cualquier parte del cuerpo para detener el balón. Su función principal es evitar que el equipo contrario marque gol.
2. **Central (*Centre Back*):** ocupa la posición central de la primera línea atacante y es el encargado de dirigir las acciones, distribuir el balón entre sus compañeros y tomar decisiones en los momentos de ataque.
3. **Lateral (*Right and Left Back*):** los laterales ocupan los extremos de la primera línea y son normalmente los jugadores con mayor capacidad de lanzamiento a larga distancia.
4. **Extremo (*Right and Left Wing*):** ocupan las posiciones más alejadas del centro del

campo, cerca de la línea de banda. Su objetivo es lanzar a portería casi sin ángulo y finalizar los contraataques rápidos.

5. **Pivote (*Line Player*):** es el jugador que actúa en la segunda línea, dentro o en las proximidades del área de portería rival. Su función es generar espacios para los lanzadores de la primera línea mediante bloqueos y apoyos, y aprovechar las situaciones cerca de la portería para anotar o provocar *7 metros* (penaltis en balonmano).

3.5. Aprendizaje automático aplicado al deporte

3.5.1. Análisis *cluster* en el deporte

Existen numerosos estudios que aplican técnicas de *clustering* en el deporte y, en este apartado, se explorarán algunos de estos trabajos. Se analizarán las técnicas utilizadas, la metodología seguida y las principales conclusiones alcanzadas en distintos deportes. La recopilación de los algoritmos y técnicas utilizadas por los estudios de otros deportes se encuentra en la Tabla 3.1 y sobre balonmano en la Tabla 3.2.

El estudio titulado *Clustering soccer players: investigating unsupervised learning on player positions* [24] tiene como finalidad evaluar si las posiciones reales de los jugadores de fútbol pueden identificarse automáticamente mediante técnicas de *clustering*. Asimismo, se compara la efectividad de *K-Means* y *Expectation Maximization (EM)* en el análisis de roles en fútbol, y se estudia tanto el número óptimo de ”tipos de jugador” como los atributos más relevantes para diferenciarlos. Los datos utilizados en este estudio se obtienen de *StatsBomb Open Data*, un repositorio que contiene información de partidos pertenecientes a distintos torneos de fútbol disputados entre 2004 y 2019, incluyendo *La Liga*. Estos datos corresponden a eventos ocurridos durante los partidos, como goles o acciones individuales de los jugadores, que posteriormente son transformados en estadísticas más generales, como disparos a portería, entre otras. Además, mediante métricas como el *Laplacian Score* y el coeficiente de correlación entre variables, se analiza la relevancia de las variables con el objetivo de eliminar variables redundantes.

Sobre el conjunto de datos preprocesado se aplican las técnicas de *K-Means* y *Expectation Maximization* mediante *Gaussian Mixture Models*. Los experimentos se realizan considerando 4, 8 y 11 *clusters*, de acuerdo con las posiciones en el campo. Los resultados muestran un mejor rendimiento de *K-Means*, evaluado mediante las métricas *Silhouette Score* y *purity*. El mejor resultado se obtiene con 8 *clusters*, mientras que el peor corresponde al caso de 11 *clusters*. Finalmente, se repiten los experimentos sin eliminar variables, obser-

vándose que la reducción de variables provoca un peor rendimiento del 37%. Como aspecto adicional, se emplea *PCA* únicamente con fines de visualización, dado que el conjunto de datos final consta de 23 variables

El estudio *Multivariate analysis of teams physical performances in official football matches in LaLiga 2023-24* [25] aplica agrupamiento de equipos en partidos de LaLiga. Este estudio busca describir el rendimiento físico de los equipos, evaluando su asociación con los rivales y la clasificación final. Los datos proceden de 756 registros de rendimiento correspondientes a 378 partidos de la primera división durante la temporada 2023-2024, recopilados mediante el sistema de seguimiento óptico *TRACAB*. Tras un proceso de normalización, se aplica *PCA* para reducir las nueve variables en tres componentes. Luego, se emplea *K-Means*, utilizando *elbow method* para conseguir un número óptimo de 4 *clusters*. Concluyendo que no existen diferencias significativas en la distribución de los *clusters* según la clasificación final de los equipos, pero sí una fuerte tendencia de los equipos a jugar partidos contra oponentes que pertenecen a su mismo *cluster* de rendimiento físico.

Otro estudio relevante es *Clustering Team Profiles in the AFL Using Performance Indicators* [26], cuyo objetivo es determinar si existen perfiles de juego de equipo en la *AFL* mediante técnicas de *clustering*. Además, se analiza si el éxito puede explicarse a partir de un único estilo de juego o de múltiples estilos, se estudia la evolución táctica de los equipos y se examinan los enfrentamientos entre diferentes estilos. Los datos empleados proceden de *Champion Data*, una base de datos oficial que recopila estadísticas detalladas de los partidos de la *AFL*. El conjunto de datos incluye 594 partidos correspondientes a las temporadas 2012, 2013 y 2014. En una primera fase, se eliminan las etiquetas relacionadas con el resultado de los partidos y la identidad de los equipos para evitar sesgos, obteniendo una representación del estilo de juego. Posteriormente, se utiliza *Random Forest* para seleccionar las variables más relevantes y, finalmente, se aplica *K-Means* para realizar el agrupamiento, determinando el número óptimo de *clusters* mediante el *elbow method*. El estudio concluye que no existe un único estilo de juego dominante y que múltiples perfiles pueden conducir al éxito, siempre que sean ejecutados correctamente.

El estudio *Clustering Professional Basketball Players by Performance* [27] tiene como objetivo analizar si los roles tradicionales de los jugadores de baloncesto profesional pueden redefinirse a partir de su rendimiento real en pista mediante técnicas de *clustering*. Asimismo, se busca identificar los perfiles de jugador que emergen de los datos y estudiar su relación con el éxito de los equipos en la *NBA*. Los datos proceden de *Basketball Reference*, una base de datos pública que recopila estadísticas avanzadas de jugadores. Se utilizan 18 métricas de rendimiento ofensivo y defensivo, normalizadas por 100 posesiones, descartando mé-

tricas de menor relevancia como las faltas personales. Posteriormente, se aplican técnicas de reducción de dimensionalidad como *PCA* y *t-SNE* con fines de visualización, decidiéndose finalmente el uso de *t-SNE* durante el preprocesamiento. A continuación, se emplea el algoritmo de *K-Means*, seleccionando el número óptimo de *clusters* mediante métricas como *Silhouette Score*, *Within-Sum-of-Squares* y *Gap Statistic*. El análisis final identifica cuatro perfiles funcionales de jugador y muestra que los equipos más exitosos no se caracterizan por acumular jugadores de un único perfil, sino por contar con jugadores especializados y diferenciados dentro de cada rol.

Siguiendo con agrupamiento en baloncesto, el estudio *Clustering performances in the NBA according to players anthropometric attributes and playing experience* [28] agrupa a los jugadores de la NBA en perfiles basados en sus atributos antropométricos y su experiencia profesional. Los datos analizados corresponden a la temporada 2015-2016. Se emplea un algoritmo de *Two-step Cluster* para caracterizar cada grupo. Los resultados identifican cinco perfiles diferenciados, concluyendo que la distribución de estos varía según el nivel de rendimiento del equipo, con una mayor presencia de jugadores experimentados en los equipos de élite.

Otro estudio relevante se centra en el hockey sobre hielo y se titula *Categorizing Playing Styles of Ice Hockey Players using Gaussian Mixture Model* [29]. En este trabajo se analizan los estilos de juego de los jugadores mediante técnicas de *clustering*. Los datos proceden de competiciones profesionales y semiprofesionales como la *SHL*, la *AHL* y *HockeyAllsvenskan*, e incluyen estadísticas individuales de los jugadores. Tras la normalización de los datos, se aplica *Non-negative Matrix Factorization* para reducir la dimensionalidad. El *clustering* se realiza mediante *Gaussian Mixture Models*, seleccionando el número de *clusters* utilizando métricas como *BIC*, *AIC* y *Silhouette Score*. Como resultado, se identifican diferentes estilos de juego y, gracias al modelo empleado, se puede analizar la evolución de los jugadores entre dichos estilos a lo largo del tiempo.

Por último, se analiza el estudio *Using K-means Clustering to Create Training Groups for Elite American Football Student-athletes Based on Game Demands* [30], desarrollado en el ámbito del fútbol americano. El objetivo de este trabajo es crear grupos de entrenamiento basados en las demandas físicas del juego. Los datos proceden de partidos oficiales de un equipo universitario. Tras un proceso de preprocesamiento y normalización, se aplica el algoritmo de *K-Means*, seleccionando manualmente el número de *clusters* entre 2 y 7. Asimismo, se utiliza *PCA* con fines de visualización. El estudio concluye que los *clusters* obtenidos presentan una alta similitud con los grupos de entrenamiento tradicionales, aunque también se identifican jugadores con demandas físicas atípicas.

Algoritmo / Técnica	Estudios
K-Means	[24], [25], [26], [27], [30]
Gaussian Mixture Models (EM)	[24], [29]
Two-step cluster	[28]
PCA (reducción dimensional / visualización)	[24], [25], [27], [30]
t-SNE (reducción dimensional / visualización)	[27]
Non-negative Matrix Factorization (NMF)	[29]
Random Forest (selección de variables)	[26]
Laplacian Score y correlación (selección de variables)	[24]

Tabla 3.1: Resumen de algoritmos de *clustering* y técnicas relacionadas aplicados en estudios de otros deportes.

3.5.2. Análisis clúster aplicado al balonmano

Este trabajo está enfocado en el deporte del balonmano, por tanto, se analizan de forma más extensa distintos estudios relacionados con este deporte y la aplicación de técnicas de *clustering*. El primer estudio de balonmano es *A New Physical Performance Classification System for Elite Handball Players: Cluster Analysis* [31], cuyo objetivo principal es identificar grupos homogéneos de jugadores en función de su desempeño físico, con el fin de facilitar la planificación de entrenamientos específicos basados en las fortalezas y debilidades individuales.

El análisis se realiza sobre una muestra de 16 jugadores masculinos de la selección nacional sub-19, considerando variables como la velocidad de *sprint*, la capacidad de salto, la velocidad de lanzamiento y distintas métricas de fuerza. Estas variables son estandarizadas y, posteriormente, se aplica un *clustering* jerárquico mediante el método de *Ward*, obteniéndose cuatro *clusters* correspondientes a diferentes perfiles físicos de los jugadores.

Los resultados indican que variables como la velocidad de lanzamiento, el esprint de 20 metros, la fuerza máxima estimada y las medidas de potencia presentan un elevado poder discriminatorio entre los distintos perfiles identificados.

Otro estudio relacionado es *A cluster analysis of high-performance handball players perceived motivational climate* [32]. El objetivo de este trabajo es identificar perfiles según el clima motivacional percibido y analizar su relación con las creencias implícitas de habilidad, la orientación motivacional y la intención de mantener la práctica física. La muestra consistió en 444 jugadores de élite españoles. Tras un análisis de *clúster* jerárquico mediante el método de Ward, se identificaron dos perfiles diferenciados. El estudio concluye que los jugadores que perciben un clima orientado a la tarea muestran niveles más altos de motivación y una mayor intención de realizar actividad física en el futuro.

El estudio *Identifying performance indicators for success in the European men's handball championships* [33] cuyo objetivo es identificar los indicadores de rendimiento que permiten diferenciar el nivel competitivo de los equipos y predecir su éxito en los campeonatos europeos de balonmano masculino. La muestra incluyó datos de 249 partidos correspondientes a cinco ediciones del campeonato europeo entre 2014 y 2022. Mediante un análisis de *clúster two-step cluster*, los equipos se agrupan en tres niveles de rendimiento: alto, medio y bajo, en función de la diferencia de goles y los puntos obtenidos por partido. Posteriormente, se aplica análisis *MANOVA* y análisis discriminante para identificar las variables que mejor diferencian estos grupos. Los resultados mostraron diferencias significativas entre los grupos en diversos indicadores ofensivos y defensivos, como la eficacia de lanzamiento, las asistencias, los robos de balón, los bloqueos, las suspensiones de dos minutos y las faltas técnicas.

El estudio *Age and Post-Based Complex Analyses of Heart Rate Variability in Young Male Handball Players for Potential Prevention of Overload-induced Injuries* [34] tiene como objetivo identificar perfiles de recuperación autonómica mediante *HRV* (Variabilidad de la Frecuencia Cardíaca) para prevenir lesiones por sobrecarga. Los datos proceden de 85 jugadores seguidos durante 11 meses, con más de 12.200 mediciones de *HRV* en reposo y antropometría. Tras un preprocesamiento con una transformación *Box-Cox* y reducción dimensional con *t-SNE*, se aplica *K-Means* con 3 clusters deducidos mediante *elbow method*. También, se utiliza *t-SNE* para visualización y árboles de decisión para interpretación. El estudio concluye que los *clusters* se separan principalmente por los niveles de *RMSSD*, alineándose con grupos de edad y posición, y permitiendo detectar desviaciones individuales de riesgo.

Otro estudio que se analiza es *Cognitive representations of handball tactic actions in athletes—The function of expertise and age* [35]. El objetivo de este trabajo es investigar las estructuras de representación mental táctica (*TMRS*) en jugadores de diferentes niveles de experiencia y edad mediante el método *Structure Dimensional Analysis of Mental Re-*

presentation (*SDA-M*). Los datos son 30 jugadores adultos y 57 jugadores juveniles. Tras un procedimiento de análisis de *clusters* jerárquicos (*Ward*) y *Adjusted Rand Index* comparado con una estructura ideal, el estudio concluye que las *TMRS* son significativamente más jerárquicas, funcionales y similares a la estructura táctica ideal en jugadores con de mayor edad, mayor experiencia y nivel regional.

El estudio *Psychological characteristics and traits in male handball players – optimism, athlete engagement and mental energy* [36]a. El objetivo de este trabajo es determinar las diferencias en las dimensiones de la batería *Multidimensional Scale of Sports' Psychological Talents* (*MSSPT*), energía mental (*MES*), engagement atlético (*AES*) y optimismo (*OS*) según club, grupo de edad, medallas y pertenencia a la selección junior, así como identificar perfiles psicológicos de los jugadores. Los datos proceden de 127 jugadores masculinos de tres clubes (*PPD Zagreb*, *Metalac* y *Zamet*). Tras pruebas no paramétricas (*Kruskal-Wallis*), *t-tests* y *clustering K-means*, el estudio concluye que las mayores diferencias son los grupos de edad, y que existen dos perfiles claros: uno de jugadores mayores con mayor autoestima y energía como fuerza ante errores, y otro de jugadores jóvenes con puntuaciones más altas en el resto de características psicológicas.

Algoritmo	**Estudios**
K-Means	[34], [36]
Clustering jerárquico (Ward)	[31], [32], [35]
Two-step cluster	[33]
t-SNE (reducción dimensional)	[34]

Tabla 3.2: Resumen de algoritmos de *clustering* y técnicas relacionadas aplicados en estudios de balonmano.

Todos estos estudios sirven para mostrar que técnicas de *clustering* y procedimientos son utilizados con mayor frecuencia en otros estudios aunque muchos estudios no enfrentan objetivos similares a los nuestros. Esto ayudará a conocer nuevas formas de preparar y agrupar los datos para los futuros experimentos. Claramente, se puede observar que los modelos más utilizados son *K-means* y el *clustering jerárquico de Ward*. Asimismo, *PCA* se emplea de forma recurrente como técnica de reducción de la dimensionalidad.

3.5.3. Aplicaciones de aprendizaje automático en deportes de equipo

Ahora, se exploran trabajos ya existentes que también clasifican o predicen alguna cualidad de los jugadores de un deporte de equipo. Igual que antes se describirán los distintos estudios para recopilar los algoritmos y métodos relacionados que se usan.

Empezando por el estudio *Analysis and Prediction of CBA Player Position Data Characteristics Based on Machine Learning* [37]. El objetivo de este trabajo es predecir la posición de campo de los jugadores de la *Chinese Basketball Association (CBA)* a partir de sus estadísticas. Los datos abarcan seis temporadas de 2017 a 2022 con 20 indicadores de rendimiento por jugador como puntos por partido, rebotes, asistencias, porcentajes de tiro, robos, tapones, etc. Se implementan y entrenan ocho clasificadores que son un árbol de decisión, análisis discriminante lineal (*Linear Discriminant Analysis*), regresión de logística multinomial, *Naive Bayes*, red neuronal,*Random Forest*, *SVM* y *XGBoost*. Tras comparar los resultados, se concluye que los modelos de *ensemble* como *Random Forest* y *XGBoost*, obtienen los mejores resultados en el conjunto de prueba. Como conclusión menciona que para las distintas posiciones hay determinadas variables que son muy influyentes a la hora de discriminar ciertas posiciones.

Otro estudio que se analiza el estudio *Towards Predicting Basketball Player Positions with Transformative Insights* [38]. Su objetivo es examinar la correlación entre las estadísticas de partido de jugadores de la *NBA* y la posición de campo oficial que tienen asignado, entrenando modelos de clasificación a partir del rendimiento estadístico. El conjunto de datos abarca desde la temporada 2004 hasta la 2023 con 407 registros y 32 variables por instancia. Principalmente, este estudio compara clasificadores como *Random Forest*, *SVM*, *K-Nearest Neighbors* y un árbol de decisión. Los resultados de ellos confirman que las posiciones oficiales presentan una correlación clara con los indicadores de rendimiento, aunque la creciente versatilidad de los jugadores introduce ambigüedad en los límites entre posiciones adyacentes, dificultando la clasificación. También, concluye que agrupar ciertas posiciones que son similares facilita el problema al equivocarse los modelos en posiciones parecidas. Esto es un problema que más adelante, sucederá en nuestro trabajo.

El estudio *Using Machine Learning to Determine the Positions of Professional Soccer Players in Terms of Biomechanical Variables* [39] busca predecir las posiciones de 20 futbolistas profesionales a partir de las exigencias locomotoras registradas durante 10 sesiones de entrenamiento con *GNSS* a 10 Hz. Se implementan y comparan *Random Forest*, *gradient boosting tree* y árboles de regresión, todos ellos con validación cruzada de 10 k. El modelo *Random Forest* alcanza un resultado muy bueno, y el análisis de importancia sobre este señala que las variables de las métricas de *sprint* y distancia a alta intensidad son las más dis-

criminantes para determinar las posiciones. Este estudio es interesante porque demuestra que incluso con variables relacionadas con los entrenamientos y pruebas médicas se puede determinar una posición aunque nuestras variables sean muy diferentes.

El estudio *Optimizing NFL Draft Selections with Machine Learning classification*[40] cuyo objetivo es predecir la posición en el *draft* de la *NFL* a partir de estadísticas, es decir, la valoración de los equipos sobre cada jugador. Se comparan una regresión, un árbol de decisión, *SVM* y *Random Forest*, este último resulta ser el mejor en todos los experimentos. El resultado es una estimación de la selección real con cinco posiciones en siete de cada diez casos, es decir, un 70% de acierto respecto a la realidad. El análisis de importancia de variables muestra que los indicadores estadísticos relevantes son específicos de cada posición, por ejemplo, *college dominator* para *wide receivers* y las estadísticas de pase y carrera para *quarterbacks*.

Algoritmo / Técnica	**Estudios**
Random Forest	[37], [38], [39], [40]
Support Vector Machine (SVM)	[37], [38], [40]
Decision Tree	[37], [38], [40]
XGBoost	[37]
Gradient Boosting Tree	[39]
Linear Discriminant Analysis (LDA)	[37]
Multinomial Logistic Regression	[37]
Naive Bayes	[37]
K-Nearest Neighbors (KNN)	[38]
Regression Tree	[39]
Linear Regression	[40]
10-Fold Cross Validation	[39]
Feature Importance Analysis	[37], [39], [40]

Tabla 3.3: Resumen de algoritmos de clasificación y técnicas relacionadas

Los resultados obtenidos muestran que algoritmos como *Random Forest*, *XGBoost* o *SVM* son capaces de identificar patrones de cada posición y alcanzar buenos resultados en la

clasificación. Además, varios estudios destacan la importancia del análisis de variables para comprender qué variables son más determinantes para los jugadores.

3.5.4. Aprendizaje supervisado aplicado al balonmano

En este apartado, se analizan trabajos relacionados con el balonmano, empezando por el estudio *Performance Prediction and Evaluation in Female Handball Players Using Machine Learning Models* [41]. El objetivo de este trabajo es evaluar diferentes modelos de *machine learning* para predecir el rendimiento en seis pruebas atléticas específicas y determinar los factores más influyentes. Los datos proceden de 59 jugadoras de balonmano del Norte de Chipre, con 23 atributos antropométricos/fisiológicos y 118 instancias registradas en dos periodos. Tras implementar y comparar regresión lineal, árbol de decisión, *SVR*, red neuronal de retropropagación, red *RBF* y *LSTM* con validación cruzada *5-fold* y *hold-out*, se concluye que la red neuronal de función de base radial (RBFNN) es claramente superior, y que los factores más relevantes son la velocidad en 10m, la edad, los pliegues cutáneos y potencia explosiva.

Otro estudio es *The PlayerScore: A Systematic Game Observation Tool to Determine Individual Player Performance in Team Handball Competition* [42]. Se centra en diseñar y validar un sistema estructurado de puntuación individual para la competición de balonmano que integra las estadísticas de partido más relevantes en un índice compuesto denominado *PlayerScore*. El instrumento se aplica sobre seis partidos del Campeonato del Mundo 2021 con seis observadores de distintos niveles de experiencia y se utiliza una regresión lineal para estudiar su éxito. Este trabajo es interesante aunque no utiliza múltiples algoritmos de aprendizaje supervisado porque muestra evidencia directa de que las estadísticas del partido permiten discriminar el rendimiento individual de los jugadores de balonmano por posición y nivel.

Por último, el estudio *Predicting Handball Matches with Machine Learning and Statistically Estimated Team Strengths* [43] trata predecir el resultado de partidos de balonmano de ligas europeas combinando estadísticas de los jugadores con estimaciones de fortaleza de equipo derivadas de una distribución *Conway-Maxwell-Poisson*. Se comparan cuatro algoritmos de aprendizaje automático que son *Random Forest*, *XGBoost*, *CatBoost* y *MLP*. Al final, el mejor modelo es *Random Forest* tanto con los datos sin la información adicional de las fortalezas de los equipos y con ellos, pero con esa información el resultado final mejora notablemente. También, demuestra la ayuda de ciertas variables para clasificar mejor ciertas clases.

Algoritmo / Técnica	Estudios
Random Forest	[43]
XGBoost	[43]
CatBoost	[43]
Multi-Layer Perceptron (MLP)	[43]
Linear Regression	[41], [42]
Decision Tree	[41]
Support Vector Regression (SVR)	[41]
Backpropagation Neural Network (BPNN)	[41]
Radial Basis Function Neural Network (RBFNN)	[41]
Long Short-Term Memory (LSTM)	[41]
5-Fold Cross Validation	[41]
Hold-out Validation	[41]
Feature Importance Analysis	[41], [43]

Tabla 3.4: Resumen de algoritmos de clasificación y técnicas relacionadas en estudios de balonmano.

Todos estos trabajos sirven para demostrar que es posible discriminar posiciones o perfiles similares con datos muy diversos desde estadísticas de competición hasta variables biomecánicas, antropométricas o de rendimiento físico. Estos resultados respaldan que es posible aplicar técnicas similares al problema abordado en este trabajo, donde se pretende analizar y clasificar jugadores de balonmano a partir de sus estadísticas de juego. En la Tabla 3.4, se recopilan todos los algoritmos coincidiendo con la Tabla 3.3 en ciertos modelos como *Random Forest*, *MLP SVM* al ser clasificadores muy sólidos con este tipo de datos estructurados.

4. Metodología

4.1. Introducción

La metodología empleada en este trabajo es *Scrum* [44], un marco de trabajo ágil diseñado originalmente para equipos de desarrollo de software que trabajan de forma colaborativa e iterativa. En su formulación estándar, *Scrum* distribuye el trabajo entre tres roles diferenciados: el *Product Owner*, responsable de definir y priorizar los requisitos del producto; el *Scrum Master*, encargado de facilitar el proceso y eliminar impedimentos; y el *Development Team*, que ejecuta el trabajo técnico. Sin embargo, dado que este Trabajo de Fin de Máster (TFM) es un proyecto individual, estos tres roles recaen sobre una única persona, el autor del trabajo, dando lugar a lo que se denomina ***Scrum* unipersonal**.

El trabajo se organiza en iteraciones de duración variable denominadas *sprints*, cada una con un objetivo concreto en un conjunto de tareas planificadas al inicio y una revisión de los resultados al final. Para realizar el seguimiento del estado de cada *sprint* y asignar nuevas tareas, se celebran semanalmente reuniones de aproximadamente una hora con los tutores del trabajo. Cada *sprint* produce dos ficheros: un *notebook* de *Jupyter* con el código desarrollado y la sección correspondiente de esta memoria con la documentación de los resultados obtenidos.

La elección de *Scrum* como metodología no es arbitraria. La naturaleza iterativa de esta resulta adecuada para un proyecto de ciencia de datos como este, en el que los resultados de cada fase condicionan directamente las decisiones de la siguiente. Por ejemplo, las conclusiones del análisis exploratorio del *Sprint 1* determinan qué variables se incluyen en el *clustering* del *Sprint 2*, y los experimentos de agrupamiento orientan el planteamiento de los experimentos de clasificación del *Sprint 3*. Esta dependencia entre fases hace que un enfoque en cascada, donde todas las decisiones se toman al inicio, sea menos adecuado que

uno iterativo, donde cada entrega parcial puede revisarse y ajustarse antes de continuar.

4.2. Planificación de *sprints*

El proyecto se organiza en cuatro *sprints* de duración variable en función de la complejidad de cada fase. Se recoge la planificación general del proyecto, indicando el objetivo principal de cada *sprint*, su duración estimada en semanas y las tareas que lo componen. La planificación del proyecto con su duración se encuentran en el diagrama de la Figura 4.1.

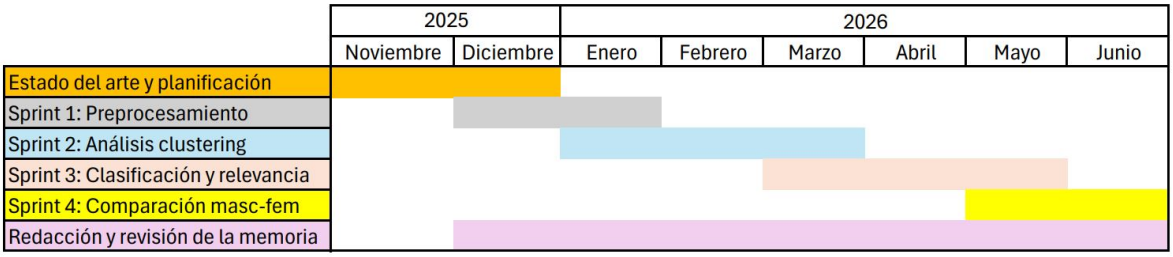


Figura 4.1: Diagrama de *Gantt* de la planificación del proyecto

A continuación se describe con más detalle el contenido y los entregables de cada sprint:

1. **Preprocesamiento**

   Obtención de los datos desde la *API* de la *EHF*, selección y transformación de variables, y exploración de los datos. El entregable de este *sprint* es un archivo *CSV* limpio para el análisis.

2. **Análisis de *clustering***

   Diseño y ejecución de los experimentos de agrupamiento sobre los jugadores de campo del torneo masculino *EHF* 2024, comparando los algoritmos *K-Means*, *Ward* y *DBSCAN* en tres experimentos (PCA2, PCA3 y RAW) para $k \in [2, 10]$. El entregable consiste en el conjunto de modelos evaluados, las visualizaciones obtenidas y la selección del modelo final.

3. **Clasificación y relevancia de variables**

   Construcción de un modelo de clasificación supervisada capaz de predecir la posición táctica de un jugador a partir de sus estadísticas de rendimiento. Además, se realiza

un análisis de importancia de variables con el objetivo de identificar las características más relevantes para la predicción. El entregable incluye el modelo entrenado, sus métricas de evaluación y el análisis de relevancia de variables.

4. **Comparativa masculino–femenino**

   Aplicación del mismo *pipeline* de preprocesamiento y metodología del *sprint 3* a los datos del torneo femenino de la *EHF* 2024, realizando posteriormente una comparación sistemática de los perfiles de rendimiento obtenidos con los del torneo masculino. El entregable final es un análisis comparativo de las diferencias y similitudes entre ambos torneos desde una perspectiva estadística y táctica.

Cada *sprint* produce dos entregables complementarios: un *notebook* de *Jupyter* con el código y la sección correspondiente de esta memoria con la documentación de los resultados.

5. Resultados

Los resultados y código desarrollado se encuentra en un repositorio cuyo enlace es: https://github.com/Chispa4013/TFM_Software_Javier_Senabre_Urrea.

5.1. *Sprint* 1: Preprocesamiento

5.1.1. Obtención de los datos

Para realizar este proyecto, el primer paso consiste en recolectar los datos sobre los distintos partidos del último Europeo de la *EHF*. En concreto, se trabaja con estadísticas individuales de rendimiento (goles, asistencias, lanzamientos, entre otras) obtenidas a lo largo de las diferentes fases del torneo. Para ello, se emplea una *API* (*Application Programming Interface*) que proporciona acceso a los datos oficiales de competiciones de balonmano, permitiendo obtener esta información mediante peticiones específicas a cada torneo.

La *API* utilizada es *"https://api-svc01.ehf.eu/"* que contiene distintos métodos para obtener información de los torneos. Los datos de los torneos están divididos por torneo, ronda y partido, facilitando las estadísticas de cada jugador o equipo. Se utilizan peticiones *HTTP GET* para obtener el conjunto de datos, por ejemplo, si se realiza la petición *"GET /Competition/GetPlayerMatchScores"*, se consiguen las métricas del torneo de todos sus participantes.

El conjunto de datos resultante contiene un número considerable de variables, concretamente 134. El número de datos puede disminuir o aumentar dependiendo del año y etapa. En este contexto, la *API* empleada adquiere un papel clave, al proporcionar acceso estructurado y automatizado a la información, garantizando su consistencia y escalabilidad, y minimizando la intervención manual en su obtención. En nuestro caso, los datos obtenidos pertenecen al campeonato europeo masculino de 2024.

5.1.2. Tratamiento de los datos y selección de variables

Una vez obtenido el conjunto de datos desde la *API* de la *EHF*, es necesario aplicar un conjunto de transformaciones previas al análisis para garantizar la calidad y coherencia del conjunto de datos en los experimentos posteriores. En primer lugar, se analiza la presencia de valores ausentes en las distintas variables del conjunto de datos, especialmente en aquellas relacionadas con estadísticas de rendimiento de los jugadores, como goles anotados (*Goals*), lanzamientos fallados (*Missed*), asistencias (*AS*), pérdidas de balón (*TO*) o bloqueos (*BS*).

Como parte del procedimiento establecido, se implementa la sustitución de valores nulos en variables numéricas por cero, interpretando la ausencia de registro como que la acción no se ha producido, así como la eliminación de aquellos registros que presenten una proporción elevada de valores ausentes. Sin embargo, tras realizar la comprobación sobre el conjunto de datos de 2024, se observa que no existen valores nulos en ninguna de las variables consideradas.

Por tanto, aunque se dispone de un protocolo de tratamiento de datos ausentes, no ha sido necesario aplicarlo en este caso. Esto refleja la calidad y consistencia de los datos proporcionados por la *API*.

El conjunto de datos contiene una gran cantidad de variables y no todas serán útiles a la hora de realizar el *clustering*, incluso podrían afectar negativamente al resultado. Por tanto, resulta necesario analizar la relevancia de las variables para determinar cuáles resultan innecesarias y pueden eliminarse.

Muchas de estas características corresponden a datos derivados obtenidos mediante transformaciones de atributos ya existentes. Como consecuencia, introducen información redundante y aumentan la dimensionalidad del conjunto de datos sin aportar conocimiento adicional. Esto incrementa el coste computacional y puede perjudicar el proceso de agrupamiento. Por este criterio, se eliminan variables que son transformaciones de otras como *averageAssists*, que representa la media de las asistencias.

No obstante, no todas las variables derivadas son perjudiciales, algunas pueden capturar información que no se encuentra explícitamente en el conjunto y mejorar la caracterización. Un ejemplo de ello son las variables asociadas a lanzamientos fallados que se calculan mediante la diferencia entre los lanzamientos acertados y lanzamientos totales como *7mPMissed*, *6mCMissed* o *9mMissed* [6].

Estas variables derivadas permiten representar de forma más precisa la eficiencia ofensiva de los jugadores, incorporando información sobre acciones fallidas que no se encuentra directamente disponible en el conjunto de datos original. El Algoritmo 5.1 muestra el pro-

cedimiento utilizado para calcular las distintas variables de lanzamientos fallados a partir de las estadísticas proporcionadas por la *API* de la *EHF*.

```
1: función ComputeMissedShots(df)
2:     df_target["9mMissed"] ← df["shots9M"] − df["goals9M"]
3:     df_target["6mCMissed"] ← df["shots6M"] − df["goals6M"]
4:     df_target["7mPMissed"] ← df["shots7M"] − df["goals7M"]
5:     df_target["WingMissed"] ← df["shotsFromWing"] − df["goalsFromWing"]
6:     df_target["BTMissed"] ← df["breakthroughs"] − df["breakthroughGoals"]
7:     df_target["FBMissed"] ← df["fastBreaks"] − df["fastBreakGoals"]
8:     devolver df_target
```

Algoritmo 5.1: Cálculo de lanzamientos fallados por tipo

La *API* no proporciona directamente las estadísticas de goles y fallos en situaciones de portería vacía, contraataque rápido o lanzamientos libres (*Fast Throw-Off*, FTO). Esta métrica resulta especialmente relevante por lo que, estas acciones se calculan por diferencia entre el total de goles registrados para el jugador y la suma de los goles contabilizados en las categorías conocidas (penaltis, zona de 6 metros, extremo, 9 metros, penetración individual y contraataque):

$$\mathit{FTOGoals} = \max\left(0,\ \mathit{goals} - \sum_{c \in C} \mathit{goals}_c\right) \tag{5.1}$$

donde $C = \{7M,\ \text{Wing},\ 6M,\ 9M,\ \text{BTM},\ \text{FB}\}$.

El uso de la función $\max(0, \cdot)$ permite evitar valores negativos que pueden aparecer debido a inconsistencias o diferencias de registro entre las estadísticas agregadas proporcionadas por la *API*.

Las posiciones tácticas devueltas por la *API* se encuentran en formato de cadena de texto con nombres largos (*Left Back*, *Right Wing*, *Goalkeeper*, etc.) y se transforman a un código abreviado, quedando "LB", "LW", "LP", "RW", "RB", "GK" y "CB". Todas las variables se renombran por nombres más cortos para facilitar su identificación y uso en futuros experimentos.

Finalmente, se seleccionan 22 variables [7] para el *clustering*, pero también existen variables identificativas que no han sido introducidas en el modelo como *Team*, *No* y *Name*, que indican el equipo del jugador, su número de dorsal y su nombre. Estas variables no contienen información relevante para el *clustering*, se utilizan únicamente para etiquetar

e interpretar los resultados. De forma similar, la variable *Position* proporciona la posición táctica del jugador en el campo.

Entre las variables utilizadas en el modelo se encuentran aquellas relacionadas con los lanzamientos, las cuales reflejan el rendimiento ofensivo de los jugadores. *7mPGoals* y *7mPMissed* recogen los goles y fallos desde la línea de 7 metros (penaltis), mientras que *6mCGoals* y *6mCMissed* representan los resultados de lanzamientos desde la zona central próxima a portería. Asimismo, *WingGoals* y *WingMissed* contienen las acciones desde posiciones de extremo, y *9mGoals* junto con *9mMissed* reflejan los lanzamientos exteriores. Otras variables relevantes son *BTGoals* y *BTMissed*, asociadas a acciones de penetración individual, *FBGoals* y *FBMissed*, correspondientes a contraataques, y *FTOGoals* junto con *FTOMissed*, vinculadas a situaciones de ataque rápido o portería vacía.

Además, incorpora estadísticas de contribución al equipo y control de juego. La variable *AS* contabiliza las asistencias que finalizan en gol, mientras que *TO* representa las pérdidas de balón. Por su parte, *Time* indica el número de minutos disputados. Desde el punto de vista defensivo, existen variables como *ST* que contabiliza los robos de balón y *BS* que registra los bloqueos de lanzamiento.

Por último, las variables por acciones disciplinarias están representadas por *RC*, *2M* y *2+2*, que indican tarjetas rojas, exclusiones temporales de dos minutos y penalizaciones dobles consecutivas.

5.1.3. Análisis exploratorio de los datos

Tras obtener el conjunto de datos que se utilizará en los experimentos, se realiza un análisis exploratorio del conjunto de datos. Además, permite identificar la influencia de ciertas variables en los experimentos futuros.

Distribución por posición

Primero, se ha explorado la distribución de jugadores por posición táctica, mostrando que es relativamente uniforme, como puede observarse en la Figura 5.1. Los laterales izquierdos (LB) son la posición más representada con 83 jugadores, mientras que los extremos izquierdos (LW) son los menos frecuentes con 46.

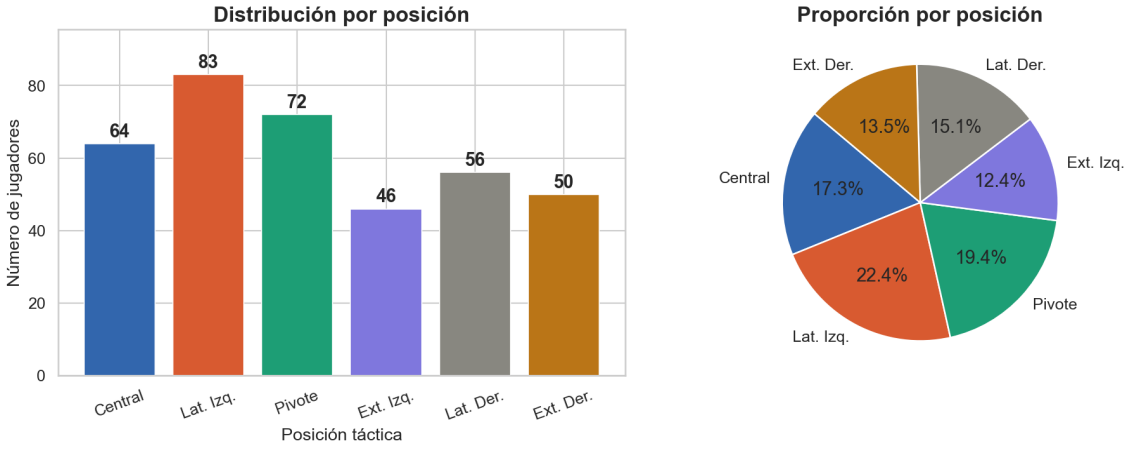


Figura 5.1: Distribución de jugadores de campo por posición.

Estadísticos descriptivos

La Figura 5.2 presenta los estadísticos descriptivos de las 22 variables. En cada variable, se muestra la media como barra principal, la desviación estándar como barras de error simétricas, el rango observado `[min -- max]` como fondo y la mediana como punto blanco.

La separación entre media y mediana es notable en todas las variables, siendo la mediana igual al valor 0 en la mayoría, lo que confirma la fuerte asimetría positiva. También, se puede observar cómo ciertas variables no varían en sus valores como *2+2* y *RC* que siempre toman el valor entero 0, lo que parece indicar que no han sido correctamente recogidas por la federación durante el torneo. Otra variable que destaca es *Time* que tiene valores considerablemente distintos al resto de variables.

Análisis de correlación

Ahora, se ha realizado una matriz de correlación entre las 22 variables (Figura 5.3) con el objetivo de analizar las relaciones entre ellas. El par con mayor correlación es *9mGoals–9mMissed* ($r = 0.86$), lo que resulta coherente porque las variables de tiros fallados se han creado a partir de la diferencia de los tiros acertados y lo más normal es que los que más goles meten desde más de 9 metros (lanzamiento exterior), también sean los que más fallen. La misma lógica aplica a los pares de goles-fallos en otras zonas (*WingGoals–WingMissed*: $r = 0.82$, *6mCGoals–6mCMissed*: $r = 0.72$, *7mPGoals–7mPMissed*: $r = 0.71$). La correlación entre *AS* y *TO* ($r = 0.84$) y entre *BTGoals* y *AS* ($r = 0.78$) apunta a que los jugadores



Figura 5.2: Estadísticos descriptivos.

con mayor participación ofensiva generan simultáneamente más asistencias y más pérdidas, reflejando su mayor volumen de acciones con balón.

Los que más minutos participan y las primeras líneas (centrales y laterales), también serán los que más acciones acumulan, finalizando en más ocasiones para bien o para mal. Los primeras líneas suelen ser los jugadores más creativos que generan las acciones en ataque para generar superioridades, lanzamientos, dar asistencias, etc

Además, la variable *2+2* no muestra ninguna correlación debido a que sus valores siempre son 0. De forma similar, *RC* tampoco muestra correlaciones fuertes al tener muy poca varianza. Otra variable interesante es *Time* que tiene cierta correlación con todas las variables porque cuanto más tiempo está un jugador compitiendo, más estadísticas generará.

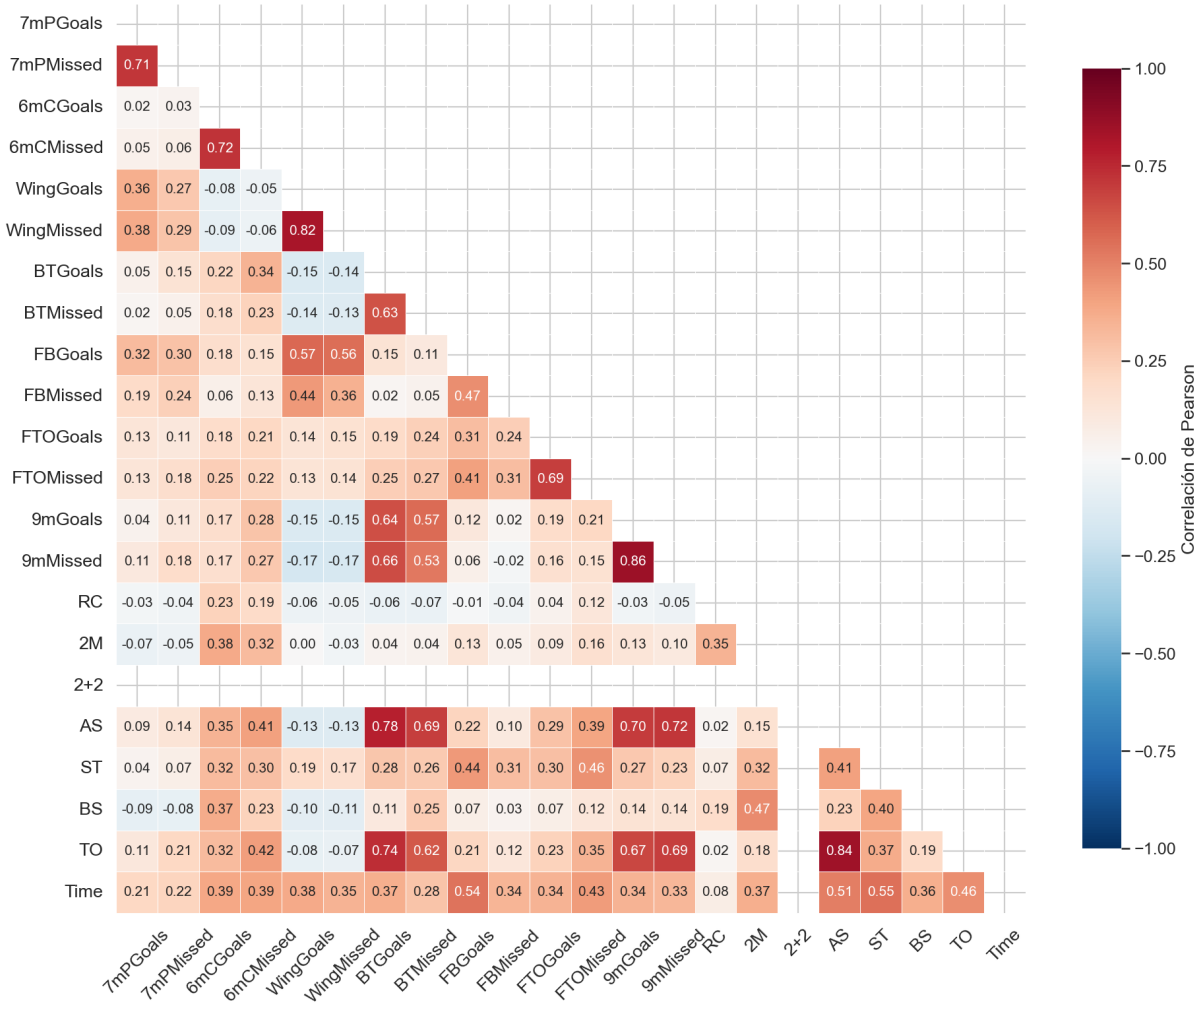


Figura 5.3: Matriz de correlación.

Distribución de ceros y asimetría

Una característica destacable del conjunto de datos es la elevada proporción de ceros en la mayoría de las variables, como consecuencia directa de la especialización de las distintas posiciones existentes en balonmano, ya que no todas las variables describen de forma ideal el rendimiento de esa posición. Como muestra el panel izquierdo de la Figura 5.4, las variables con mayor porcentaje de ceros son *7mPMissed* (87%), *7mPGoals* (86%) y *FBMissed* (86%), mientras que las menos afectadas son *AS* (33%) y *TO* (34%). También, se reafirma lo mencionado anteriormente sobre las variables *2+2* y *RC* al tener un 100% y 96% de ceros.

Esta concentración de ceros produce distribuciones fuertemente asimétricas hacia la derecha en todas las variables, como confirma el panel derecho de la Figura 5.4. Los coeficientes de asimetría oscilan entre 2.07 (*TO*) y 5.72 (*RC*), lo que representa un comportamiento coherente, ya que solo ciertas variables son relevantes para las distintas posiciones, porque no todas las posiciones participan en las mismas acciones ofensivas o defensivas, por ejemplo, los porteros apenas registran lanzamientos acertados o goles anotados debido a que su función principal se centra en tareas defensivas.

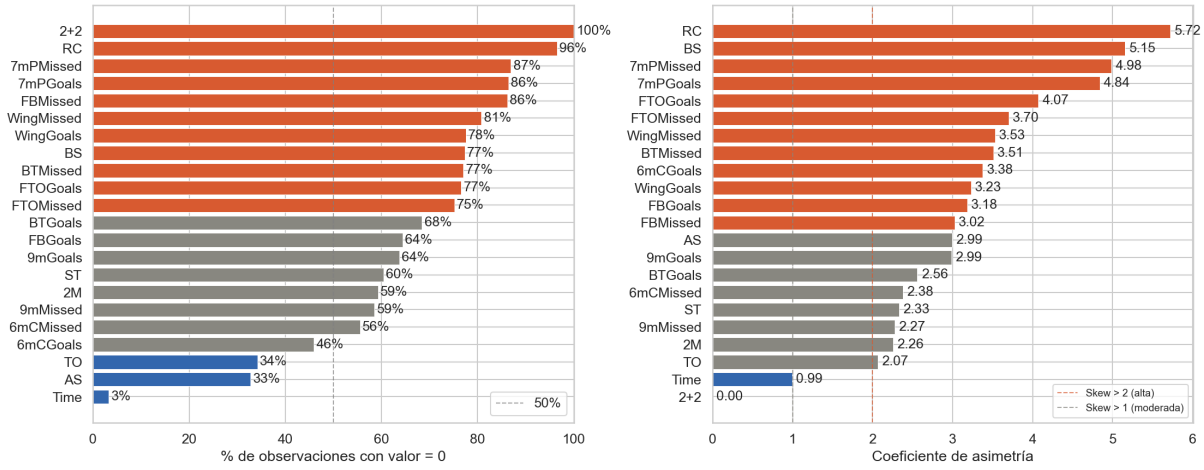


Figura 5.4: Proporción de ceros y asimetría por variable.

Detección de valores atípicos

Se identifican valores atípicos como observaciones que superan el umbral $\mu + 3\sigma$ en cada variable. Las variables con mayor número de valores atípicos son *WingGoals* (15 jugadores), *FBMissed* y *ST* (14 jugadores cada una). Los *outliers* identificados corresponden a jugadores

de élite reconocibles como Ludovic Fabregas (37 goles de pivote, máximo en *6mCGoals*), Dika Mem (30 goles exteriores, máximo en *9mGoals*), Nedim Remili (53 asistencias, máximo en *AS*) o Julian Köster (17 bloqueos, máximo en *BS*).

Este análisis confirma que los valores extremos son estadísticamente legítimos y responden a rendimientos excepcionales en el torneo, no a errores de registro. Por este motivo, no se elimina ningún registro del conjunto de datos. Más adelante, la estandarización *Z-score* aplicada en el preprocesamiento gestiona estos valores de forma robusta, tal como se justifica en la Sección 5.2.5.

5.1.4. Conclusión de la exploración

Se toman una serie de decisiones sobre el conjunto de datos para mejorar el resultado del resto de *Sprints*. Estas decisiones y su justificación se documentan en esta sección.

Eliminación de *RC* y *2+2*

Las variables *RC* (tarjetas rojas) y *2+2* (exclusiones dobles consecutivas) se eliminan por carecer de varianza. La variable *2+2* tiene valor cero en la totalidad de los 427 registros del conjunto de datos ($\sigma = 0.000$), por lo que no aporta ninguna información discriminante. La variable *RC* solo presenta valores distintos de cero en 15 jugadores del total (3.5%), con una media de 0.037 y una desviación estándar de 0.202. Por tanto, ambas variables solo contribuyen a añadir ruido al cálculo de distancias. En jugadores de alto rendimiento, cómo es el caso en un campeonato de Europa no suelen darse estas acciones. Las acciones 2+2 son por cometer una infracción de exclusión de 2 minutos y luego consecutivamente protestar o realizar otra, esto con jugadores profesionales no pasa prácticamente nunca. Similar sucede con tarjeta roja.

Eliminación de porteros

Los porteros se eliminan del conjunto de datos porque, tras el análisis previo del conjunto de datos, se detecta que la *API* no registra las variables necesarias para detectar de forma efectiva el rendimiento de los porteros. Las variables existentes representan correctamente el resto de posiciones, pero incluir a los 56 porteros generaría un grupo con mucho ruido, distorsionando los datos y reduciendo la capacidad de los algoritmos para identificar patrones de rendimiento entre los jugadores de campo. Tras su eliminación, el conjunto de datos final queda compuesto por 371 jugadores.

5.2. Sprint 2: Análisis *Clustering*

5.2.1. Introducción

Este *Sprint* tiene como objetivo un análisis *clustering* de los datos obtenidos del campeonato europeo masculino de 2024. Se estructura en tres experimentos, utilizando dos algoritmos de *clustering* y tres preprocesamientos distintos. El experimento consiste en la ejecución de los algoritmos de agrupamiento *K-Means*, *Ward* y *DBSCAN* con un determinado preprocesamiento. El resto de experimentos tan solo varían en el preprocesamiento de los datos, siendo:

- **Experimento 1 (*PCA2*):** Sobre los datos se aplica el preprocesamiento *PCA* para reducir las variables a 2 componentes principales.
- **Experimento 2 (*PCA3*):** Igual que el experimento anterior pero reduciendo las variables a 3 componentes principales.
- **Experimento 3 (Datos originales):** Se utilizan directamente los datos estandarizados sin ningún tipo de reducción de dimensionalidad, conservando las variables y la totalidad de la información.

Para cada experimento, se explora el rango de $k \in [2, 10]$ grupos y se compara el resultado de los tres algoritmos mediante las métricas *elbow* y *Silhouette*. También, se establece una semilla aleatoria para garantizar la reproducibilidad de los resultados, en nuestro caso, se fija en 42 y se mantiene a lo largo de todo el trabajo.

Principalmente, todo este *Sprint* con sus diversos experimentos se realiza para lograr el segundo objetivo de este proyecto. Además, experimentar con distintos algoritmos y preprocesamientos permite estudiar el rendimiento de todas las configuraciones planteadas y determinar qué configuraciones son las mejores para este tipo de datos, de forma que estos resultados puedan ser utilizados en futuros trabajos en este campo.

5.2.2. *K-means*

Se implementa una función `kmeans_experiment` específicamente para el algoritmo *K-Means* que ejecuta el agrupamiento para $k \in [2, 10]$ en cada uno de los tres experimentos. Se utiliza la clase `KMeans` [45] de la librería *scikit-learn* con los siguientes hiperparámetros:

- `n_clusters=k`: número de grupos a formar.

- `random_state=42`: semilla aleatoria para garantizar la reproducibilidad de los resultados.

- `n_init=20`: número de inicializaciones distintas que se ejecutan, seleccionando la solución de menor inercia.

En cada iteración se registra la inercia, definida como la suma de distancias cuadráticas de cada punto a su centroide más cercano, y el coeficiente de *Silhouette*. A partir de estas dos métricas se generan automáticamente la curva *elbow*, que representa la inercia en función de k y permite identificar cuando la ganancia de compacidad decrece, y la curva de *Silhouette* que mide la cohesión y separación de los grupos.

Adicionalmente, para facilitar la interpretación visual, se genera una cuadrícula de diagramas de dispersión sobre los datos con un *PCA* de dos dimensiones que muestra la partición obtenida para cada valor de k, así como una comparativa entre la agrupación para $k = 6$ y la distribución real de posiciones de los jugadores. Esto facilita la visualización para las pruebas, como demuestra el ejemplo $k = 6$ de la Figura 5.5.

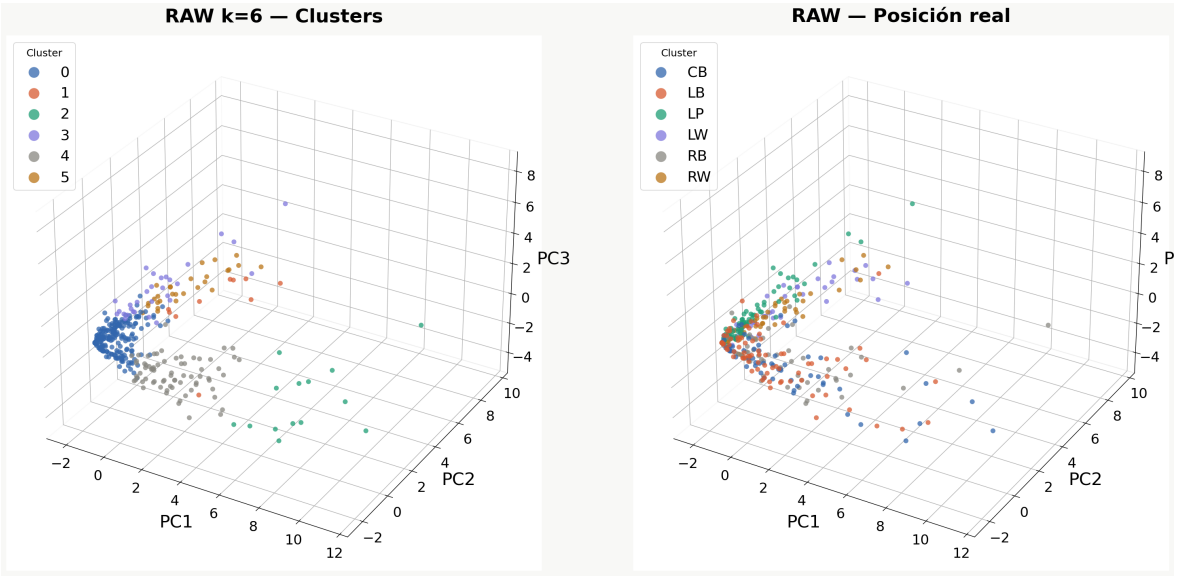


Figura 5.5: Comparativa entre *clusters* del algoritmo *K-Means* y posiciones reales

5.2.3. *Clustering jerárquico Ward*

El *clustering jerárquico Ward* se implementa mediante la función `ward_experiment`. La implementación combina dos herramientas de *scikit-learn* [46] y *scipy*:

- `linkage` de *scipy*: Seleccionando el método *Ward* como parámetros, se calcula el árbol jerárquico completo y se genera el dendrograma.
- `Agglomerative Clustering` de *scikit-learn*: asigna los clusters para cada valor de k cortando el árbol a la altura correspondiente.

A diferencia de *K-Means*, el algoritmo utilizado por el clustering jerárquico *Ward* presenta una serie de ventajas como no necesitar múltiples inicializaciones ya que el proceso de construcción del árbol es determinista, es decir, no es necesario probar distintos números de inicializaciones.

5.2.4. DBSCAN

Durante el desarrollo del experimento se implementa también el algoritmo *DBSCAN* (*Density-Based Spatial Clustering of Applications with Noise*) como tercera alternativa. A diferencia de *K-Means* y *Ward*, *DBSCAN* no requiere especificar el número de *clusters* de antemano y es capaz de identificar puntos de ruido, es decir, observaciones que no pertenecen a ningún grupo por encontrarse en zonas de baja densidad. Sus dos hiperparámetros son *eps* (radio de vecindad) y *min_samples* (número mínimo de puntos para formar un núcleo).

Sin embargo, los resultados obtenidos con este método no han sido muy prometedores ya que se clasifica una gran proporción de jugadores como ruido. Un total de 322 jugadores clasificados como ruido, siendo incorrecto como se puede observar en la Figura 5.6, por ello, *DBSCAN* no resulta adecuado para este problema y se descarta en favor de *K-Means* y *Ward*.

5.2.5. Escalado de las variables

Para mejorar los resultados de los algoritmos de *clustering* se realiza una estandarización a las variables. Este tipo de algoritmos normalmente basados en distancias euclídeas, como *K-Means* y el *clustering* jerárquico de *Ward*, son especialmente sensibles a la escala de las variables, Una variable con rango amplio, como el tiempo de juego en minutos, dominaría el cálculo de distancias sobre variables de conteo con valores pequeños, como los bloqueos o los robos de balón.

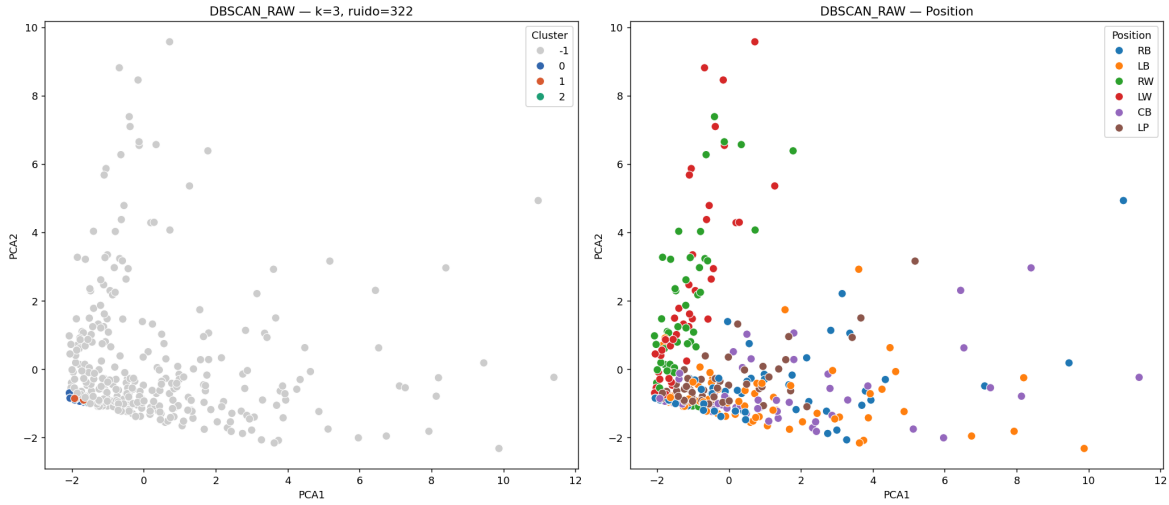


Figura 5.6: Comparativa entre *clusters* del algoritmo *DBSCAN* y posiciones reales

Para corregir este efecto se aplica una estandarización *Z-score* mediante la transformación:

$$x' = \frac{x - \mu}{\sigma}, \tag{5.2}$$

donde μ es la media de la variable sobre el conjunto de jugadores y σ es su desviación estándar.

También, se consideró la alternativa de normalizar con *Min-Max*, que transforma cada variable al intervalo $[0, 1]$ según:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}. \tag{5.3}$$

Sin embargo, esta opción se descartó por su sensibilidad a los valores extremos. En un torneo de élite como la *EHF*, existen jugadores con estadísticas altas en determinadas variables que actúan como *outliers*, comprimiendo al resto de jugadores en una franja estrecha del intervalo $[0, 1]$ y distorsionando las distancias entre los jugadores con rendimiento medio, que constituyen la mayor parte de la muestra. La estandarización *Z-score* es más robusta ante esta situación al no estar anclada a los valores extremos observados. La estandarización se implementa mediante `StandardScaler` de *scikit-learn*.

5.2.6. Reducción de dimensionalidad: PCA

El Análisis de Componentes Principales (*Principal Component Analysis*, *PCA*) es una técnica de reducción de dimensionalidad no supervisada que transforma un conjunto de variables correlacionadas en un nuevo conjunto de componentes no correlacionados, ordenados de forma que los primeros retienen la mayor parte de la varianza del conjunto de datos original [47]. Cada componente se obtiene como una combinación lineal de las variables originales, calculada a partir de los autovectores de la matriz de covarianza.

El conjunto de datos presenta un gran número de variables, dificultando su visualización mediante gráficas bidimensionales al tener múltiples dimensiones. Sin embargo, al aplicar *PCA*, es posible reducir su dimensionalidad a 2 o 3 componentes principales, permitiendo representar y visualizar los datos de forma más sencilla en gráficas de 2 o 3 dimensiones.

También, pueden utilizarse esta reducción de variables como preprocesamiento de los datos para compactar las variables y quizás mejorar los resultados. La reducción a 2 o 3 dimensiones supone una pérdida de información que puede dificultar la separación de grupos que requieran más de dos ejes para distinguirse.

5.2.7. Análisis del impacto de la variable *Time*

La variable *Time* registra los minutos disputados por cada jugador en el torneo, con valores que oscilan entre 0 y 467 minutos. El problema fundamental de incluirla en el *clustering* es que actúa como una variable que correlaciona positivamente con prácticamente todas las variables de rendimiento, con correlaciones de Pearson que van desde 0.23 (*7mPGoals*) hasta 0.62 (*ST* y *FBGoals*). Un jugador que ha disputado el doble de minutos que otro tenderá a registrar más goles, asistencias y pérdidas, no porque su rendimiento sea mejor o peor sino porque ha tenido más tiempo para acumular estadísticas. En consecuencia, *Time* puede forzar al algoritmo a agrupar a los jugadores por su nivel de participación en lugar de por su perfil de rendimiento.

Para cuantificar este efecto se ejecutan los experimentos *K-Means* con y sin *Time*. Tras ejecutar los experimentos y analizar las pruebas, se toma la decisión final de **excluir *Time***, obteniendo un número total de **19 variables**.

5.2.8. Generación de los resultados

Para cada combinación de experimento (*exp*), algoritmo y valor de k (número de *clusters*) se genera automáticamente la siguiente estructura de directorios y ficheros:

- `clusters_output/{exp}/plots/`: figuras de comparación visual (*grid* de *scatterplots* para $k = 2..10$), curva del *elbow*, Silhouette y comparativa *clusters* vs. posición para $k = 6$.
- `clusters_output/{exp}/k={k}/csv/`: CSV con todos los jugadores y su asignación de *cluster* (incluyendo *Name*, *Team*, *No* y *Position*), un CSV por *cluster* y un fichero de estadísticos descriptivos por grupo.
- `clusters_output/{exp}/k={k}/stats/`: gráficos de barras horizontales con estadísticos por *cluster*, gráficos de radar y *scatterplot* 3D coloreado por *cluster* y por posición.

Adicionalmente, se genera un fichero de resumen global `global_summary.csv` con el *Silhouette* de *K-Means* y *Ward*, y el *ARI* entre ambos métodos para cada experimento y cada k.

5.2.9. Resultados de *K-Means* y *Clustering jerárquico Ward*

Al terminar los experimentos se obtienen una cantidad significativa de datos para analizar, pero no resulta viable profundizar en todos ellos porque algunos experimentos ofrecerán mejores resultados que otros y dedicar el mismo nivel de análisis a todos supondría un uso ineficiente del tiempo, obligando a elegir un experimento y k interesantes. Por ello, la elección del número de grupos óptimo k se realiza combinando la curva del codo (*elbow*) y el coeficiente de *Silhouette*.

Selección del experimento.

Como se observa en la Figura 5.7, los experimentos *PCA2* y *PCA3* alcanzan coeficientes de Silhouette superiores a los del experimento *RAW* para *K-Means*. Sin embargo, este resultado no implica que los grupos obtenidos con *PCA* sean de mayor calidad. La reducción de dimensionalidad comprime la información de múltiples variables y tiende a producir grupos aparentemente más compactos y separados, inflando artificialmente el coeficiente de Silhouette sin que ello se corresponda necesariamente con una mejor separación en el espacio original de 19 variables. Las curvas del codo de *PCA2* y *PCA3* presentan además una caída más pronunciada y sostenida que la de *RAW*.

Desde el punto de vista del análisis deportivo, la reducción a 2 o 3 componentes principales implica una pérdida de información que puede resultar crítica. Si en un análisis se desea estudiar un conjunto de jugadores, la información descartada en las variables elimi-

nadas puede distorsionar la agrupación, ocultando diferencias de rendimiento que sí serían capturadas en las variables originales.

Además, tras analizar superficialmente los resultados de cada experimento, los resultados del experimento *RAW* son mejores y más interpretables que el resto de experimentos. Por tanto, se opta por elegir el experimento *RAW* como experimento de referencia para todo el análisis, aunque también se han analizado el resto y se hablará sobre ellos, especialmente sobre el experimento *PCA3*.

También se debe elegir entre los resultados de los algoritmos *K-Means* y *Ward*. *K-Means* obtiene valores de *Silhouette* superiores a *Ward* de forma consistente en los tres experimentos. La diferencia es notable en el experimento RAW, donde Ward desciende abruptamente a partir de $k = 6$ hasta valores de 0.15, mientras que *K-Means* se mantiene estable en torno a 0.30. Por tanto, se opta por *K-Means* como algoritmo para el análisis en profundidad.

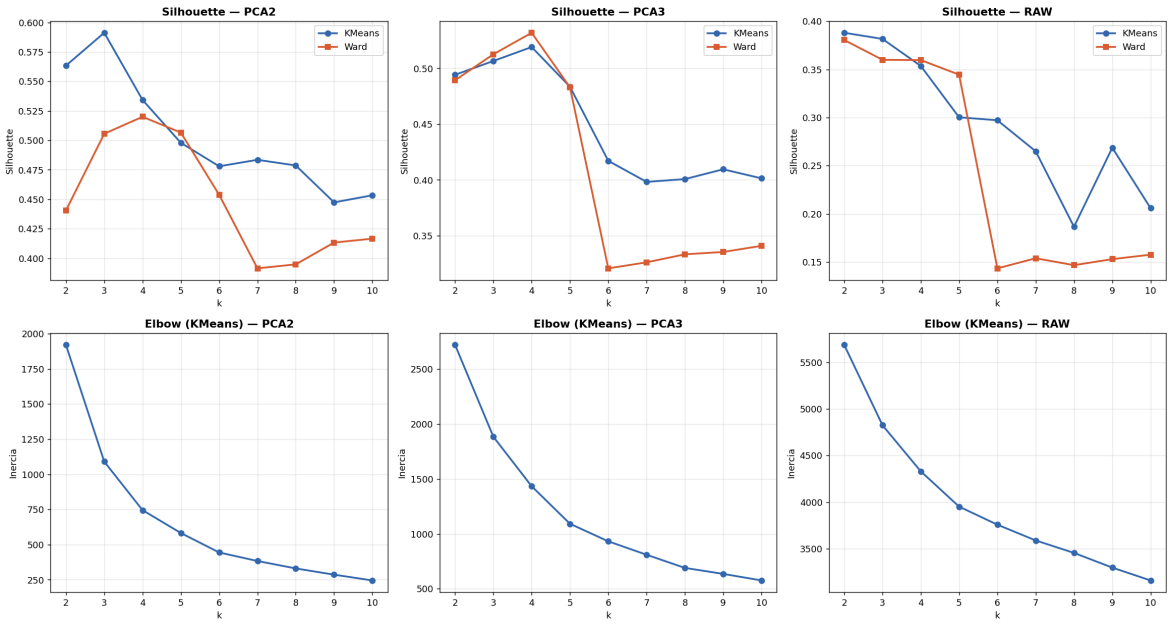


Figura 5.7: Comparativa del coeficiente de Silhouette y elbow para *K-Means* y *Ward* en los tres experimentos (*PCA2*, *PCA3* y *RAW*)

Selección de k.

En el experimento *RAW*, la curva de *Silhouette* de *K-Means* presenta su valor más elevado en $k = 2$ (0.38), descendiendo hasta $k = 5$ (0.30) y estabilizándose en los valores $k \in \{5, 6\}$ antes de degradarse progresivamente. *Ward* muestra un comportamiento similar hasta $k = 5$ (0.35), pero experimenta un descenso abrupto a partir de $k = 6$, alcanzando

valores de aproximadamente 0.15 que se mantienen hasta $k = 10$, lo que indica que el algoritmo pierde capacidad de separación. La curva *elbow* del experimento *RAW* confirma este diagnóstico, ya que la inercia desciende con mayor pendiente hasta $k = 4$ o $k = 5$. Como se puede ver en la figura 5.7.

A pesar de que los valores más altos de *Silhouette* corresponden a $k = 2$, esta partición resulta demasiado simple para el objetivo del análisis. Distinguir perfiles de rendimiento en un torneo de élite requiere una granularidad mínima que permita separar no solo pivotes de extremos, sino también niveles de rendimiento dentro de cada posición. Por ello, se analizan en detalle las particiones $k \in \{4, 5, 6\}$ que representan el equilibrio entre buenas métricas y buena interpretación.

Experimento *RAW*

A continuación, se analizan los resultados del experimento *RAW* con el número de clústeres antes justificado.

$k = 4$. Con cuatro grupos surgen perfiles bien diferenciados que se corresponden en gran medida con las posiciones de juego. El *cluster 0* contiene los mejores jugadores de las primeras líneas (centrales y laterales) del torneo, con valores elevados de goles desde 9 metros, goles de penetración, goles desde 6 metros y asistencias. El *cluster 1* concentra jugadores de todas las posiciones con escasas acciones determinantes, y, probablemente, menor tiempo de participación. El *cluster 2* es un grupo formado casi totalmente por pivotes, destacando en un alto número de lanzamientos y goles desde 6 metros. El *cluster 3* agrupa a los extremos (*"Wing"*), caracterizándose en contraataques y lanzamientos desde la posición de extremo. Los diferentes *clusters* pueden observarse en la Figura 5.8, donde se representan los atributos principales de las observaciones agrupadas en cada uno de ellos.

$k = 5$. Al aumentar a cinco grupos, el *cluster 0* anterior se subdivide en dos niveles de rendimiento, dividiendo en dos grupos a los jugadores de primera linea en el *cluster 0* y *cluster 2*. El *cluster 2* recoge los jugadores más determinantes de las primeras líneas con el mayor número de acciones ofensivas positivas, y el *cluster 4* concentra los jugadores de las primeras líneas de menor eficacia y peor porcentaje de lanzamiento. El *cluster 0* contiene los perfiles de pivotes coincidiendo con el *cluster 3* de $k = 4$. El *cluster 1* sigue manteniendo a los jugadores con menos tiempo de participación o peores, teniendo estadísticas muy bajas. Por último, el *cluster 3* representa principalmente a los jugadores con posición en los extremos, destacando en los tiros exitosos desde los extremos, contraataques y 7 metros.

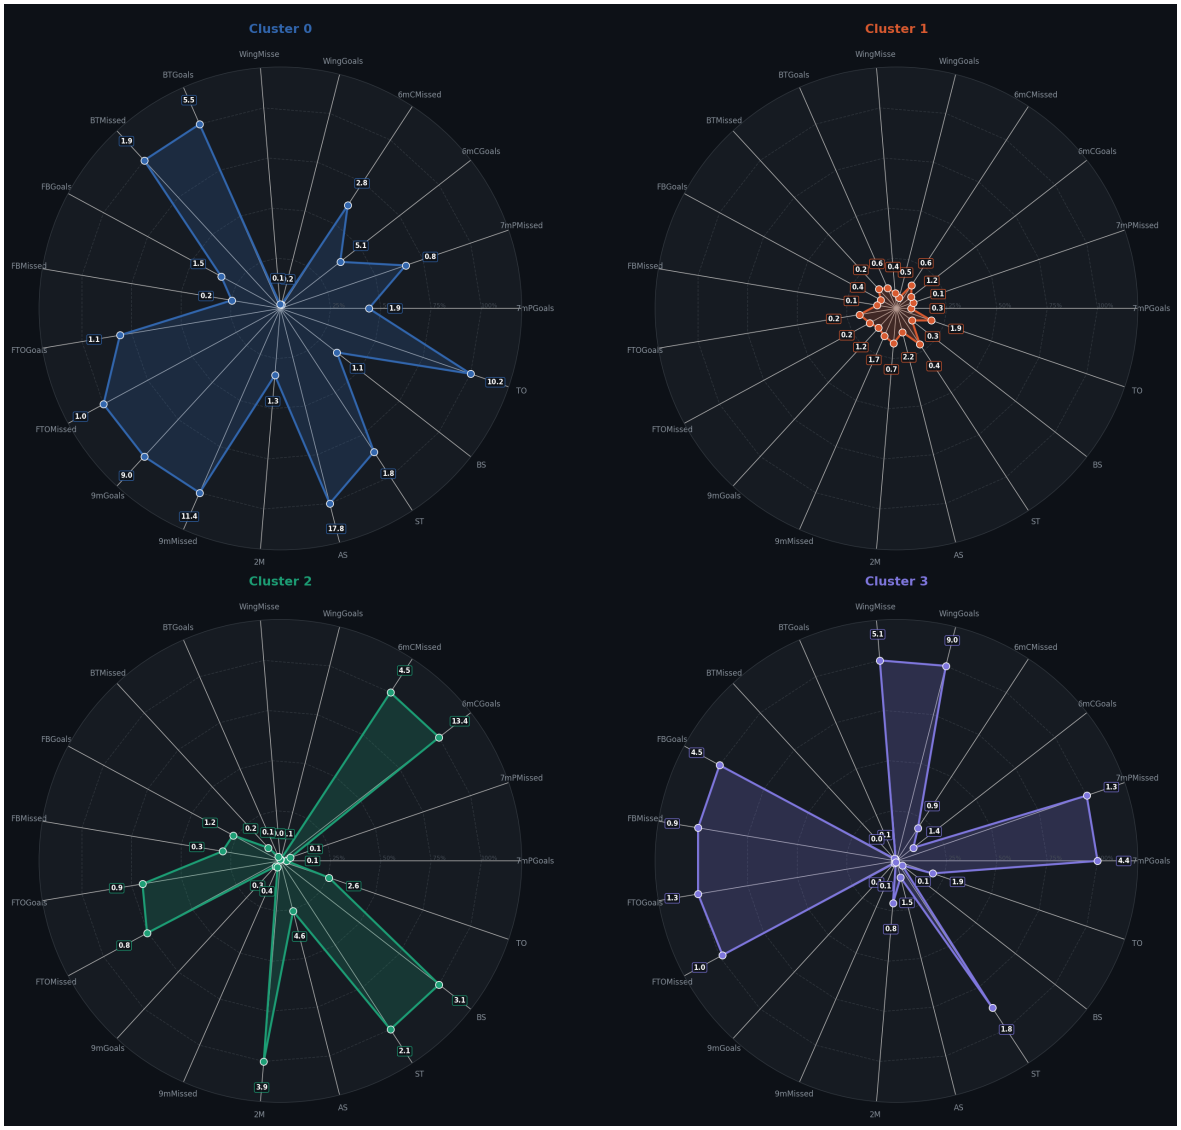


Figura 5.8: Atributos de los *clusters* para $k = 4$**.**

$k = 6$**.** Con seis grupos se produce también la división del *cluster* de los jugadores de la primeras líneas, transformándose en los *clusters 2 y 4*, presentando el primero a los jugadores de primera línea más determinantes y el resto de jugadores de estas posiciones menos determinantes en otro *cluster*. No obstante, los extremos también sufren esta división, conteniendo el *cluster 1* que agrupa a los extremos más destacados, con abundantes goles desde el extremo, contraataques y lanzamientos de 7 metros, mientras el *cluster 5* recoge a los extremos de menor nivel con menos lanzamientos de 7 metros. El *cluster 0* conserva el grupo de jugadores con escasa participación o rendimiento reducido.

Experimentos PCA

Los resultados con reducción a dos o tres componentes principales son similares a los obtenidos con los datos originales sin transformar (Experimento *RAW*). Con $k = 4$ existe el *cluster 0* con jugadores de escasa participación o importancia, el *cluster 1* con jugadores determinantes de las primeras líneas, el *cluster 2* contiene a los extremos con un número elevado de contraataques y lanzamientos de 7 metros, y el último *cluster* preserva los pivotes definidos por los goles desde 6 metros. La principal diferencia entre los experimentos *PCA* y *RAW* es la separación menos clara entre los grupos como consecuencia de la pérdida de información causada por la reducción de dimensionalidad.

Conclusiones del análisis

El análisis de *clustering* sobre los 371 jugadores del torneo ha demostrado que los algoritmos de agrupamiento son capaces de estructurar los jugadores de forma lógica y útil sin ninguna información previa sobre las posiciones. La estructura consiste en cuatro perfiles que corresponden con los roles del balonmano moderno definidos. Los grupos que se crean de forma general son las primeras líneas con alta incidencia ofensiva, los pivotes definidos por tiros a 6 metros, los extremos caracterizados por el contraataque y el lanzamiento desde el extremo, y un grupo de jugadores con menor participación o un bajo rendimiento. A medida que aumenta k, esta estructura no se rompe sino evoluciona a grupos que se subdividen en niveles de rendimiento, esto indica que se puede agrupar de forma efectiva a los distintos jugadores a partir de sus estadísticas.

5.2.10. Resultados del agrupamiento por clase

Además del análisis global, se ha llevado a cabo un experimento aplicando el algoritmo *K-Means* con preprocesamiento *RAW* de forma independiente sobre cada posición de juego antes mencionadas (centrales, laterales, extremos y pivotes). Se han juntado las posiciones simétricas, es decir, aquellas que solo se diferencian si están en la izquierda o derecha del campo, por ejemplo, los laterales. El objetivo es comprobar si al eliminar la variabilidad entre posiciones, el algoritmo es capaz de distinguir niveles de rendimiento dentro de una misma posición. Los valores de k analizados son los mejores resultados que ofrecen según las métricas de *elbow* y *Silhouette*, y la interpretabilidad de sus resultados.

Centrales ($k = 2$). Con dos grupos, el algoritmo separa los centrales más determinantes del torneo del resto. El primer *cluster* (grupo de élite) agrupa a 9 jugadores, pero son los más

diferenciales del torneo europeo. Sus estadísticas en goles desde 9 metros, penetraciones y asistencias los distinguen del segundo grupo, formado por los 55 centrales restantes con un rendimiento inferior.

Lo más llamativo es la validación externa de este resultado, aparecen 6 de los 7 jugadores nominados a MVP ("Most Valuable Player") en este primer *cluster*. Los jugadores del primer cluster están en la tabla 5.1, marcados en negro están los jugadores nominados [48]. Los tres restantes que no entran son jugadores con grandes estadísticas individuales cuyos equipos no llegaron a las fases finales del torneo, lo que reduce su visibilidad en las estadísticas pero no necesariamente su nivel. El algoritmo sin conocer las nominaciones ha identificado prácticamente el mismo grupo de élite que los expertos de la federación.

Jugador	**Selección**
Lukas Hutecek	AUT
Elias Ellefsen á	FAR
Skipagøtu	FAR
Nedim Remili	FRA
Aleks Vlah	SLO
Felix Claar	SWE
Jim Gottfridsson	SWE
Luc Steins	NED
Juri Knorr	GER
Máté Lékai	HUN

Tabla 5.1: Jugadores del primer *cluster* en la posición central.

Laterales ($k = 2$). En el caso de los laterales, $k = 2$ forma un primer grupo de 106 jugadores y un segundo de 33 que concentra a los laterales más importantes. La diferencia entre ambos grupos es enorme, los 33 laterales del grupo de élite que acumulan de media 5.87 goles desde 6 metros por jugador son mucho mejores frente a los 0.87 del segundo grupo. En los lanzamientos desde 9 metros, la diferencia es aún más pronunciada, teniendo una media de 9.67 goles por jugador frente a 2.87. Como ocurre con los centrales, la similitud con las nominaciones de la *EHF* es muy alta, apareciendo 10 de los 14 jugadores nominados a *MVP* en las posiciones de lateral izquierdo y lateral derecho.

Laterales ($k = 5$). Al aumentar a cinco grupos, la partición binaria anterior se descompone en perfiles más específicos. El algoritmo deja de agrupar simplemente por nivel y empieza a

distinguir también por características técnicas, por ejemplo, uno de los *cluster*es agrupa a los buenos laterales que son lanzadores habituales de 7 metros, un perfil particular dentro de esta posición. En general, la partición ordena primero por nivel y después por las variables con mayor frecuencia para cada lateral, ofreciendo una visión más granular aunque algo más difícil de interpretar que la de $k = 2$.

Extremos ($k = 2$). El patrón de $k = 2$ se repite con los extremos. Apareciendo un *cluster* de 34 jugadores relevantes y uno de 63 con menor protagonismo en el torneo. Los extremos del grupo relevante acumulan de media 8.76 goles desde el extremo (*WingGoals*) por jugador frente a los 1.95 del otro grupo, y 4.58 goles en contraataque frente a tan solo 0.74. La validación con las nominaciones de la *EHF* vuelve a ser muy positiva: 11 de los 12 nominados a *MVP* en las posiciones de extremo están en el *cluster* de mayor rendimiento, un resultado que no puede atribuirse al azar.

Extremos ($k = 3$). Con tres grupos, el primer *cluster* recoge 6 extremos con muy poca actividad en el torneo, apenas 1.33 goles desde el extremo y 0.5 en contraataque de media. El segundo agrupa a 56 extremos con estadísticas algo mejores pero por debajo de la media de la competición (2.01 goles desde el extremo y 0.77 en contraataque). El tercer *cluster* contiene a los 35 mejores extremos del torneo, con medias de 8.77 *WingGoals* y 4.59 goles en contraataque, valores muy parecidos al *cluster* de élite de $k = 2$. Esto confirma de cierta manera la estabilidad del grupo independientemente del k elegido.

Pivotes ($k = 2$). En los pivotes la variable dominante es el gol desde 6 metros (*6mCGoals*) que define casi por completo el resultado del algoritmo en esta posición. Con $k = 2$, se separan 54 pivotes con una media de 4.78 goles desde 6 metros de los 18 más determinantes que alcanzan una media de 15.88. De estos 18, 5 de 7 están nominados a *MVP* por la EHF.

Pivotes ($k = 3$). La división en tres grupos es idéntica a la de $k = 2$ con la diferencia de que el algoritmo identifica un tercer *cluster* formado únicamente por los 2 pivotes del torneo que se encargan de los lanzamientos de penalti de 7 metros. Al ser un perfil atípico dentro de la posición, sus características los alejan del resto, algo bastante sorprendente.

Conclusiones del análisis de *clustering* por posición

El experimento de *clustering* por posición muestra una estructura que divide según el rendimiento para valores pequeños de k, pero cambia para k mayores, separando los grupos

por estilo de juego o comportamientos muy específicos, por ejemplo detecta los extremos que lanzan los penaltis o 7 metros.

También, muestra el éxito del algoritmo al agrupar los mejores jugadores, sin conocer las nominaciones de los expertos de la EHF, el algoritmo ha destacado los jugadores que coinciden con los nominados por los expertos de la *EHF*. Acertando aproximadamente 80% de los jugadores nominados, mostrando un resultado sólido y que no se puede atribuir al azar. Los jugadores agrupados en clúster de mayor nivel que no fueron nominados por *EHF* tenían grandes estadísticas en la competición, con lo cual el grupo tiene un patrón coherente y similar.

Estos resultados muestran que es posible utilizar este tipo de análisis como herramienta de *scouting automatizado*. Esto permitiría que un sistema de *clustering* bien configurado pudiera identificar de forma rápida y reproducible los perfiles de élite dentro de cada posición, en lugar de revisar manualmente las estadísticas de cientos de jugadores.

5.3. Sprint 3: Clasificación y relevancia de variables

5.3.1. Introducción

Este *Sprint* aborda la clasificación supervisada de jugadores en función de su posición en balonmano, utilizando las estadísticas de rendimiento individuales como variables para la clasificación del anterior *Sprint*, es decir, del campeonato europeo masculino de 2024. El objetivo es determinar si las estadísticas de un jugador permiten inferir su posición en el campo. Para ello, se plantean dos experimentos que se diferencian en el número de clases de la variable objetivo:

- **Experimento 1 (EXP1):** Se consideran las seis posiciones originales del balonmano de campo lateral izquierdo (*LB*), lateral derecho (*RB*), extremo izquierdo (*LW*), extremo derecho (*RW*), central (*CB*) y pivote (*LP*) excluyendo a los porteros (*GK*) por los motivos anteriormente mencionados. El problema se formula por tanto como una clasificación de 6 clases.
- **Experimento 2 (EXP2):** Se agrupan las posiciones simétricas para reducir el riesgo de error de la clasificación al no existir estadísticas que ayuden a diferenciarlos. Los extremos izquierdo y derecho se fusionan en la clase *Wing/Extremo*, y los laterales izquierdo y derecho en la clase *Lateral*. El central y el pivote se mantienen como categorías independientes, quedando una clasificación con 4 clases.

Para cada experimento se evalúan cuatro algoritmos de clasificación *Random Forest*, *XGBoost*, *SVM* y una red neuronal *MLP*. Todos ellos ajustados mediante búsqueda en malla (o *grid search* en inglés), que consiste en probar distintas combinaciones de hiperpárametros y validar con validación cruzada para establecer la mejor combinación. Adicionalmente, el mejor modelo de cada experimento es seleccionado para realizar un análisis de importancia de variables basado en *SHAP*, tanto a nivel global como por clase. El objetivo principal no es obtener el clasificador con la mayor tasa de acierto, sino crear un modelo con un rendimiento suficientemente bueno que permita interpretar sus decisiones. En concreto, se pretende identificar qué variables influyen en la clasificación de un jugador en una determinada posición de juego, extrayendo información sobre los factores más relevantes para dicha clasificación. Al igual que en el *Sprint* anterior, se fija la semilla aleatoria en 42 para garantizar la reproducibilidad de todos los resultados.

5.3.2. Configuración inicial del experimento

En ambos experimentos, se utilizan las mismas 19 variables de rendimiento definidas en el análisis de *clustering*, excluyendo la variable *Time* por las razones expuestas en la Sección 5.2.7. También, los datos de cada experimento se dividen en entrenamiento (80%) y prueba (20%) mediante una partición estratificada para preservar la distribución de clases. Esta división en dos conjuntos permite disponer de un conjunto independiente para evaluar la capacidad de generalización del modelo y evitar que el conjunto de prueba influya en el entrenamiento.

Se aplica el mismo proceso de estandarización del *sprint* anterior de la Sección 5.2.5, teniendo especial cuidado debido al riesgo de fuga de datos al estandarizar los datos de entrenamiento con información del conjunto de prueba. Por ello, se realiza un *pipeline* [49] que consiste en una secuencia automatizada de distintas etapas que incluye la transformación *Z-score* de los datos y la aplicación del algoritmo de clasificación para la clasificación de la posición de campo. Con esta estructura, se asegura que los parámetros de la estandarización se calculen únicamente a partir de los datos de entrenamiento.

5.3.3. Ajuste de hiperparámetros

Los distintos modelos tienen muchos hiperparámetros que afectan el resultado, por ello, hallar la mejor combinación es importante. Entonces, se utiliza una búsqueda en malla con la implementación de *GridSearchCV* [50] de *sklearn* que ejecuta múltiples veces el modelo con las distintas combinaciones hasta encontrar la mejor y para validar los modelos se configura

una validación cruzada estratificada de $k = 5$ sobre el conjunto de entrenamiento.

Random Forest

El hiperparámetro *n_estimators* determina el número de árboles que forman el modelo. En general, un mayor número de árboles reduce la varianza y mejora la estabilidad de las predicciones, aunque también aumenta el tiempo de entrenamiento. Por su parte, *max_depth* limita la profundidad máxima de cada árbol, ayudando a controlar el sobreajuste. Si se establece en *None*, los árboles pueden crecer sin restricciones. Los parámetros *min_samples_split* y *min_samples_leaf* fijan, respectivamente, el número mínimo de muestras necesario para dividir un nodo y el número mínimo de muestras que debe contener una hoja. El hiperparámetro *max_features* indica cuántas variables se consideran en cada división del árbol, introduciendo aleatoriedad y reduciendo la correlación entre los árboles del bosque. Finalmente, se emplea `class_weight='balanced'` para compensar el desbalance entre clases, asignando un mayor peso a aquellas con menor representación.. Los valores de los hiperparámetros explorados se encuentran en la Tabla 5.2.

Hiperparámetro	**Valores explorados**
`n_estimators`	50, 100, 200, 300, 350, 400
`max_depth`	3, 7, 10, 20, `None`
`min_samples_leaf`	1, 2, 3, 5
`min_samples_split`	2, 3, 4, 5
`max_features`	`None`, `sqrt`, `log2`

Tabla 5.2: Hiperparámetros para *Random Forest*

XGBoost

N_estimators y *learning_rate* actúan como el número total de arboles y su tasa de aprendizaje. *Max_depth* controla la profundidad limite de cada árbol, si es demasiado alto sufrirá sobreajuste. *Subsample* y *colsample_bytree* establecen la proporción de la selección aleatoria de instancias y variables con la que cada árbol se entrena, evitando que los arboles sean muy parecidos. *Reg_alpha* aplica regularización L_1 sobre los pesos de las hojas, favoreciendo la posibilidad soluciones nuevas. *Min_child_weight* establece el peso mínimo de instancias necesario para crear un nodo hijo, dando control adicional sobre el sobreajuste para las clases menos presentes. Los valores de los hiperparámetros explorados se encuen-

tran en la Tabla 5.3.

Hiperparámetro	Valores explorados
`n_estimators`	10, 15, 25, 75, 100, 150, 200
`max_depth`	2, 5, 6, 10, 15, 20
`learning_rate`	0.1, 0.3, 0.5
`subsample`	0.4, 0.7, 0.9
`colsample_bytree`	0.4, 0.7, 0.9
`reg_alpha`	0.4, 0.7, 0.9
`min_child_weight`	1, 2, 3, 5

Tabla 5.3: Hiperparámetros para *XGBoost*

SVM

El hiperparámetro C maneja el equilibrio entre el margen de separación y la penalización de los errores. Con valores bajos se prioriza un margen amplio aunque se toleren más errores, mientras que con valores altos el hiperplano se ajusta con más rigidez a los datos de entrenamiento, lo que por otro lado puede conllevar un sobreaprendizaje. *Gamma* determina el radio de influencia de cada punto de soporte de forma que valores altos generan frontera con mayor riesgo de sobreajuste. El *kernel* define cómo se transforma el espacio de características en un espacio de dimensión mayor, lo que permite separar clases que no son linealmente separables. Igual que en *Random Forest*, se activa *class_weight='balanced'*. Además de *probability=True* para poder estimar probabilidades de clase. Los valores de los hiperparámetros explorados se encuentran en la Tabla 5.4.

Hiperparámetro	Valores explorados
`C`	0.001, 0.01, 0.1, 0.5, 1.0, 1.5, 2.0, 5.0, 10.0, 50.0, 100.0
`gamma`	`scale`, `auto`, 0.001, 0.01, 0.1, 1.0
`kernel`	*rbf*, lineal, sigmoide, polinómico

Tabla 5.4: Hiperparámetros para *SVM*

Red neuronal (*MLP*)

La arquitectura de las capas ocultas de la red neuronal están fijadas en *hidden_layer_sizes* que determina el número de capas y de neuronas por capa. *Activation* establece la función de activación de las neuronas. El tamaño de lote (*batch_size*) controla cuántas muestras se procesan antes de actualizar los pesos de la red, mientras que la tasa de aprendizaje inicial (*learning_rate_init*) regula el aprendizaje de estas. Por último, el hiperparámetro α aplica una regularización L_2 sobre los pesos de la red para ayudar a reducir el sobreajuste. Los valores de los hiperparámetros explorados se encuentran en la Tabla 5.5.

Hiperparámetro	**Valores explorados**
`hidden_layer_sizes`	(32,), (64,), (32, 16), (64, 32), (128, 64), (256, 128), (128, 64, 32), (256, 128, 64), (512, 256, 128), (512, 256, 128, 64), (512, 256, 128, 64, 32), (1024, 512, 256, 128, 64, 32)
`activation`	*relu*, *tanh*
`alpha`	0.0001, 0.0005, 0.001, 0.005, 0.01
`learning_rate_init`	0.0001, 0.0005, 0.001, 0.005
`learning_rate`	*adaptive*, *constant*

Tabla 5.5: Espacio de búsqueda de hiperparámetros para la red neuronal *MLP*

Las tablas 5.6 y 5.7 recogen las configuraciones de hiperparámetros seleccionadas tras el proceso de *GridSearchCV* con validación cruzada estratificada para cada uno de los cuatro modelos, en el experimento 1 y el experimento 2 respectivamente.

5.3.4. Resultados de los experimentos

Una vez los modelos entrenados y ajustados en ambos experimentos, se empieza a inferir con ellos para evaluar su rendimiento. Primero, en cada experimento se comparan las métricas y luego, se revisan las matrices de confusión que permiten ver con más detalle en qué posiciones clasifican correctamente o cuales son problemáticas para los modelos. Luego, con el mejor modelo entre los dos experimentos, se entrena una versión final utilizando todos de los datos disponibles y sobre ese modelo final se realiza el análisis de importancia de variables con *SHAP*, tanto a nivel global como por clase.

Modelo	Configuración seleccionada
Random Forest	`n_estimators=50, max_depth=None, max_features=sqrt, min_samples_leaf=3, min_samples_split=2`
XGBoost	`n_estimators=25, max_depth=2, learning_rate=0.5, subsample=0.4, colsample_bytree=0.7, reg_alpha=0.9, min_child_weight=1`
SVM	`C=1.0, gamma=scale, kernel=linear`
Red Neuronal	`hidden_layer_sizes=(128, 64), activation=relu, alpha=0.005, learning_rate=adaptive, learning_rate_init=0.005`

Tabla 5.6: Mejores hiperparámetros por modelo del experimento 1 Masculino 2024

Modelo	Configuración seleccionada
Random Forest	`n_estimators=100, max_depth=None, max_features=sqrt, min_samples_leaf=1, min_samples_split=5`
XGBoost	`n_estimators=15, max_depth=5, learning_rate=0.1, subsample=0.9, colsample_bytree=0.4, reg_alpha=0.4, min_child_weight=2`
SVM	`C=100.0, gamma=0.01, kernel=rbf`
Red Neuronal	`hidden_layer_sizes=(512, 256, 128, 64), activation=relu, alpha=0.005, learning_rate=adaptive, learning_rate_init=0.005`

Tabla 5.7: Mejores hiperparámetros por modelo del experimento 2 Masculino 2024

Experimento 1

La Tabla 5.8 recoge las métricas de los cuatro modelos sobre el experimento 1 (EXP1) y la exactitud (*accuracy*) de la validación cruzada. Lo primero que se aprecia es que ningún modelo supera el 51% de accuracy en CV (*cross-validation*), lo que sugiere que se trata de un problema complejo. Con respecto al accuracy en el conjunto de test, el *SVM* obtiene el mejor resultado con un 48%, *Random Forest* y *XGBoost* se quedan en el 44,0%, y la red neuronal en el 45,3%. Esto resulta extraño debido a que *Random Forest* y *XGBoost* suelen ofrecer mejores resultados al ser modelos que suelen ser mejores con este tipo de datos. Esto sugiere que los datos no son los más adecuados para lograr este ajuste, como se verá posteriormente en el experimento 2.

Modelo	CV Acc.	Test Acc.	F1 (weighted)	F1 (macro)	Precision
Random Forest	0.500	0.440	0.442	0.418	0.465
XGBoost	0.507	0.440	0.434	0.415	0.455
SVM	0.507	0.480	0.488	0.459	0.531
Red Neuronal	0.500	0.453	0.408	0.381	0.395

Tabla 5.8: Métricas globales del experimento 1

En cuanto a las matrices de confusión que corresponden a la Figura 5.9, se puede observar que la posición más fácil de clasificar es pivote. En el lado contrario, los laterales (*LB* y *RB*) se confunden entre sí, lo que se traduce en columnas y filas bastante repartidas en lugar de concentradas en la diagonal. Esto también le sucede a la posición de extremos (*LW* y *RW*), mostrando un problema del planteamiento de este problema. Los modelos clasifican mal estas posiciones simétricas porque no existen estadísticas que permitan distinguirlas. La posición central (*CB*) y los laterales (*LB* y *RB*) fallan entre ellos debido a que su perfil estadístico se mezcla bastante.

Experimento 2

Los resultados anteriores ponen de manifiesto que es necesario agrupar las posiciones simétricas en el terreno de juego, lo cual nos ha permitido verificar que las métricas mejoran en los cuatro modelos como se puede ver en Tabla 5.9. *Random Forest* pasa a considerarse el mejor modelo con un 76,0% de accuracy sobre los datos de test, seguido de cerca por *XGBoost* (73,3%) y la red neuronal (72,0%). La *SVM* que en experimento 1 había sido el mejor,

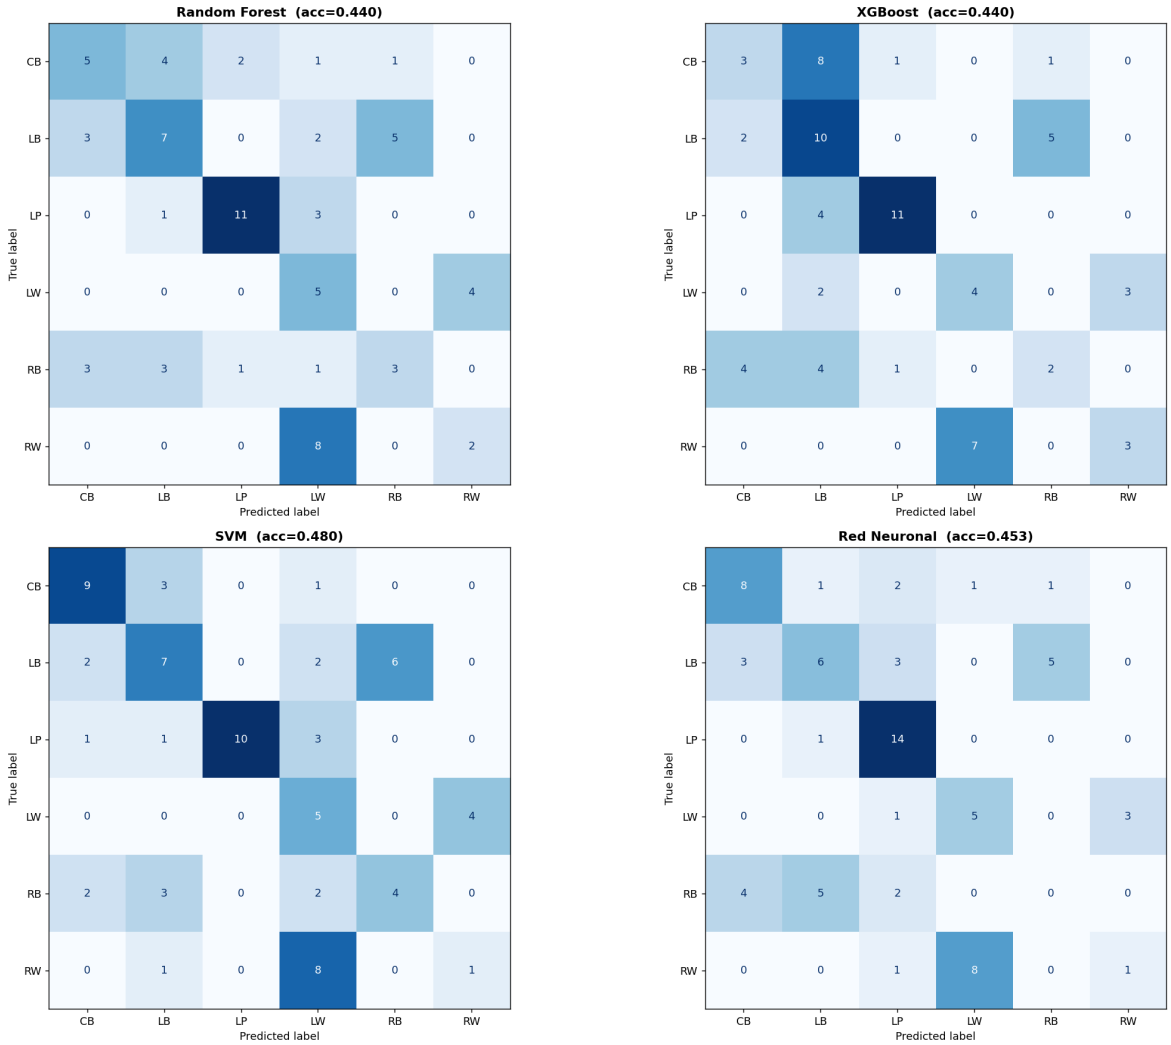


Figura 5.9: Matrices de confusión de los cuatro modelos (6 posiciones)

se queda ahora última con un 64,0% de acierto, así que parece que es el modelo que menos se beneficia de simplificar el problema. *XGBoost* y la red neuronal (*MLP*) tienen un mejor acierto en la validación cruzada, pero la tasa de acierto en el conjunto de pruebas es menor y concretamente, son muy inferiores en *F1*. Por este equilibrio entre las métricas, se decide escoger *Random Forest* como mejor modelo.

Modelo	CV Acc.	Test Acc.	F1 (weighted)	F1 (macro)	Precision
Random Forest	0.723	0.760	0.761	0.741	0.762
XGBoost	0.753	0.733	0.683	0.635	0.804
SVM	0.676	0.640	0.648	0.642	0.700
Red Neuronal	0.737	0.720	0.709	0.687	0.744

Tabla 5.9: Métricas globales del experimento 2

Las matrices de confusión de la Figura 5.10 muestran un patrón mucho mejor que en el experimento 1. Los extremos (*Wing*) son el grupo mejor clasificado en los cuatro modelos, con prácticamente todos sus aciertos concentrados en la diagonal. Los laterales mejoran también de forma notable con *Random Forest* clasifica correctamente 22 de 28 jugadores y *XGBoost* llega a clasificar correctamente los 28. El *Pivote* se mantiene igual que antes en los cuatro modelos. Ahora, que los laterales y extremos no se confunden entre sí, la posición *central* se convierte en el problema de clasificación principal. Por ejemplo, En *XGBoost*, 10 de los 13 centrales reales se predicen como *Lateral*, así que el modelo básicamente confunde a los centrales con los laterales casi todo el tiempo. *Random Forest* es más tolerante a este problema al fallar menos.

Con todo esto, queda claro que el experimento 2 soluciona el problema principal del experimento 1 al simplificar el problema de las posiciones simétricas. Esto sugiere que el problema no es de los modelos, sino del propio planteamiento del experimento 1 donde las posiciones de laterales y extremos de izquierda y derecha son estadísticamente indistinguibles entre sí. Por mucho que se ajusten los hiperparámetros no se puede superar ese problema porque viene marcado por los datos y el planteamiento inicial, y eso se nota tanto en la validación cruzada como en el resto de métricas. Por ello, el experimento 2 al agrupar estas clases elimina el problema y mejora globalmente el resultado, eligiéndolo para el análisis de importancia de variables y como mejor modelo a*Random Forest* que combina el mayor acierto con el comportamiento más equilibrado entre clases.

No obstante, la confusión de los modelos entre centrales y laterales sigue presente por-

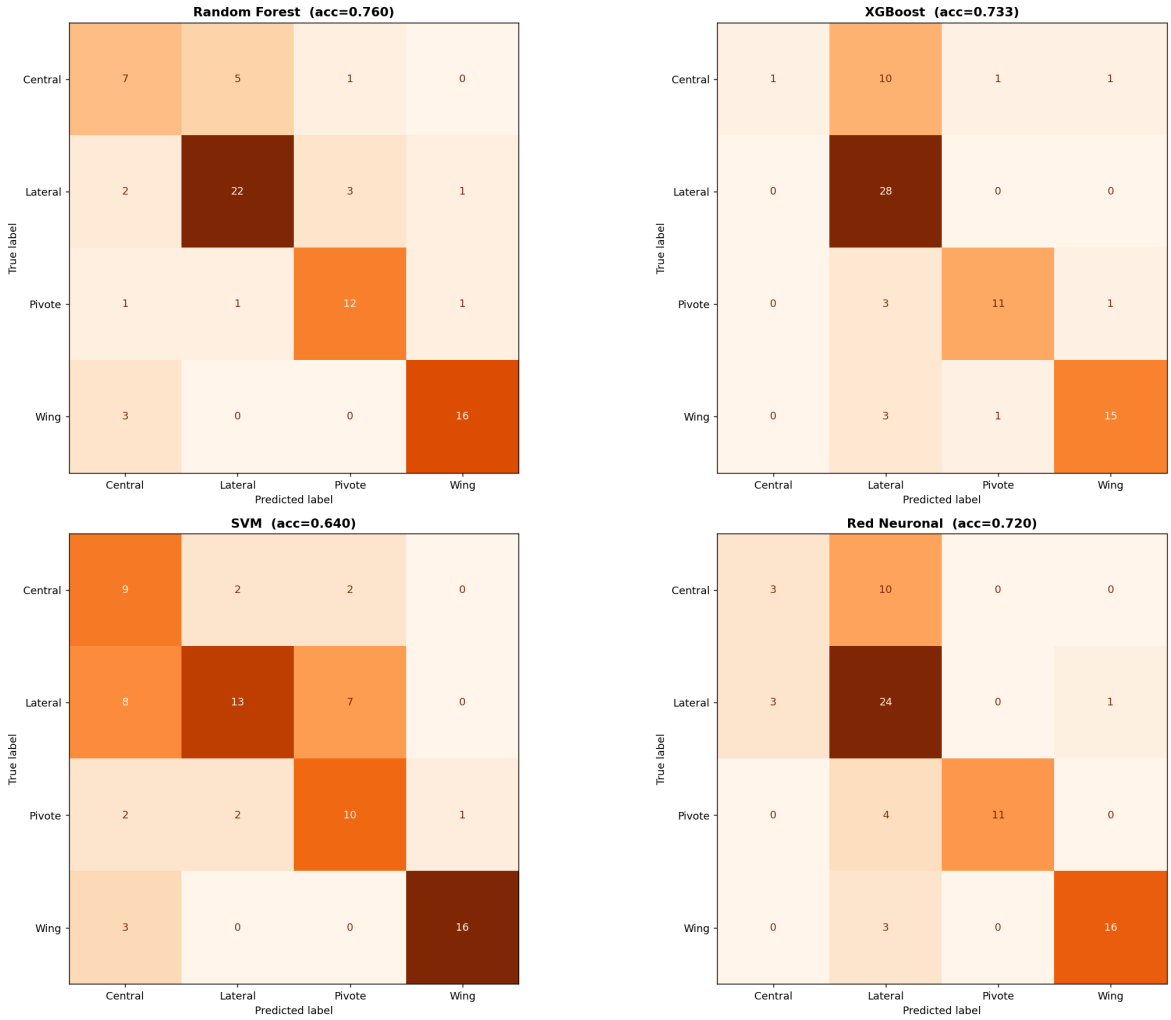


Figura 5.10: Matrices de confusión de los cuatro modelos (4 posiciones)

que estas dos posiciones tienen perfiles muy similares con los datos existentes. Además, durante el juego es habitual que los jugadores de estas posiciones intercambien sus roles con frecuencia, lo que dificulta aún más su diferenciación por parte de los modelos.

5.3.5. Importancia de las variables

Evaluados los modelos de ambos experimentos y seleccionado *Random Forest* como mejor modelo, se realiza un análisis interpretativo *SHAP* sobre todos los datos de los conjuntos del experimento 2, es decir, el 100% de los datos, para obtener estimaciones de importancia más estables que las que se obtendrían entrenando solo con el 80% de los datos. *SHAP* puede tomar valores positivos o negativos en función de si contribuye a aumentar o disminuir la probabilidad de una clase concreta. Por ello, para cada variable se calcula la media del valor absoluto de sus contribuciones*SHAP* a lo largo de todas las instancias y clases, obteniéndose así la *media* $|SHAP|$. Un valor más elevado indica que dicha variable tiene una mayor influencia en las predicciones del modelo.

A nivel global como se muestra en la Figura 5.11 con la modalidad masculina, las variables más determinantes para la clasificación son los lanzamientos fallados desde nueve metros (*9mMissed*) y los goles de extremo (*WingGoals*). Les siguen los goles de nueve metros (*9mGoals*), los lanzamientos fallados de extremo (*WingMissed*), los goles de seis metros en zona central (*6mCGoals*) y los goles en penetración (*BTGoals*). A partir de *6mCMissed* la importancia cae de forma progresiva.

En cuanto a la importancia global de la variables en categoría masculina, cabe destacar que en alto rendimiento lo más diferencial es no fallar lanzamientos desde más de 9 metros (*9mMissed*). La tercera variable está directamente relacionada, ya que es el número de goles desde más de 9 metros (*9mGoals*). Por lo tanto, es fundamental a este nivel contar con jugadores que fallen poco lanzamiento exterior y tengan goles de fuera, la efectividad en este lanzamiento es determinante. Con los lanzamientos desde los extremos (*WingGoals*) pasa muy similar ya que aparecen en segunda y cuarta posición en cuanto a importancia. Estos resultados son consecuencias del alto nivel defensivo en balonmano masculino, con defensas cada vez con más altura y movilidad, son muros muchas veces infranqueables dónde marcar goles desde más distancias y desde zonas exteriores como lo son los extremos es determinante.

No obstante, el desglose por clase de la Figura 5.12 revela la razón detrás de la contribución de las variables antes mencionadas. El *Central* presenta el perfil más distribuido con la variable *AS* (asistencias) seguido por *WingGoals* y *TO* (pérdidas de balón). El grupo *Lateral* se apoya principalmente en el lanzamiento desde 9 metros (*9mMissed* y *9mGoals*) seguidos

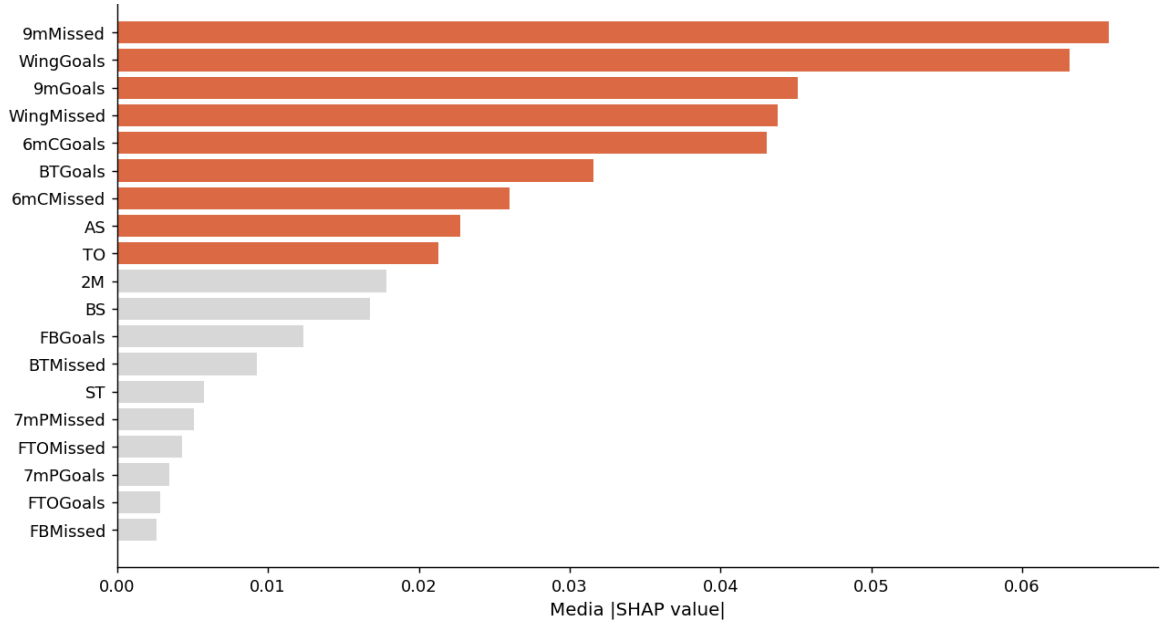


Figura 5.11: Importancia global de las variables (*Random Forest*) del torneo masculino

de *BTGoals* y *6mCGoals*. El *Pivote* presenta una combinación más peculiar con *6mCGoals* y *9mMissed* encabezando su importancia. Por último, *Extremo* es el grupo con la variable más discriminatoria que es *WingGoals* y *WingMissed* que separan con mucha claridad esta clase del resto, lo que explica por qué es la clase mejor clasificada en todos los modelos. Además, es coherente porque los extremos son los jugadores que principalmente realizan lanzamientos desde los extremos (*WingGoals*).

La Figura 5.12 denota las nuevas tendencias del balonmano masculino de alto rendimiento. En cuanto a los centrales son jugadores con poco gol y que hacen jugar a los equipos y que deben hacer goles en zonas de extremos con capacidad de finalización por zona exterior. Los laterales la nueva tendencia es priorizar que sean jugadores con gol y cada vez ya dan menos asistencias a los pivotes. En el caso de los pivotes faltaría una variable importante que no recoge la *EHF* que son los penaltis (7 metros) que provocan en los partidos. Y en cuanto a los extremos antes era muy importante los goles de contraataque pero en el balonmano actual cada vez con una mejor preparación física es más complicado que esto sea diferencial en alto rendimiento.

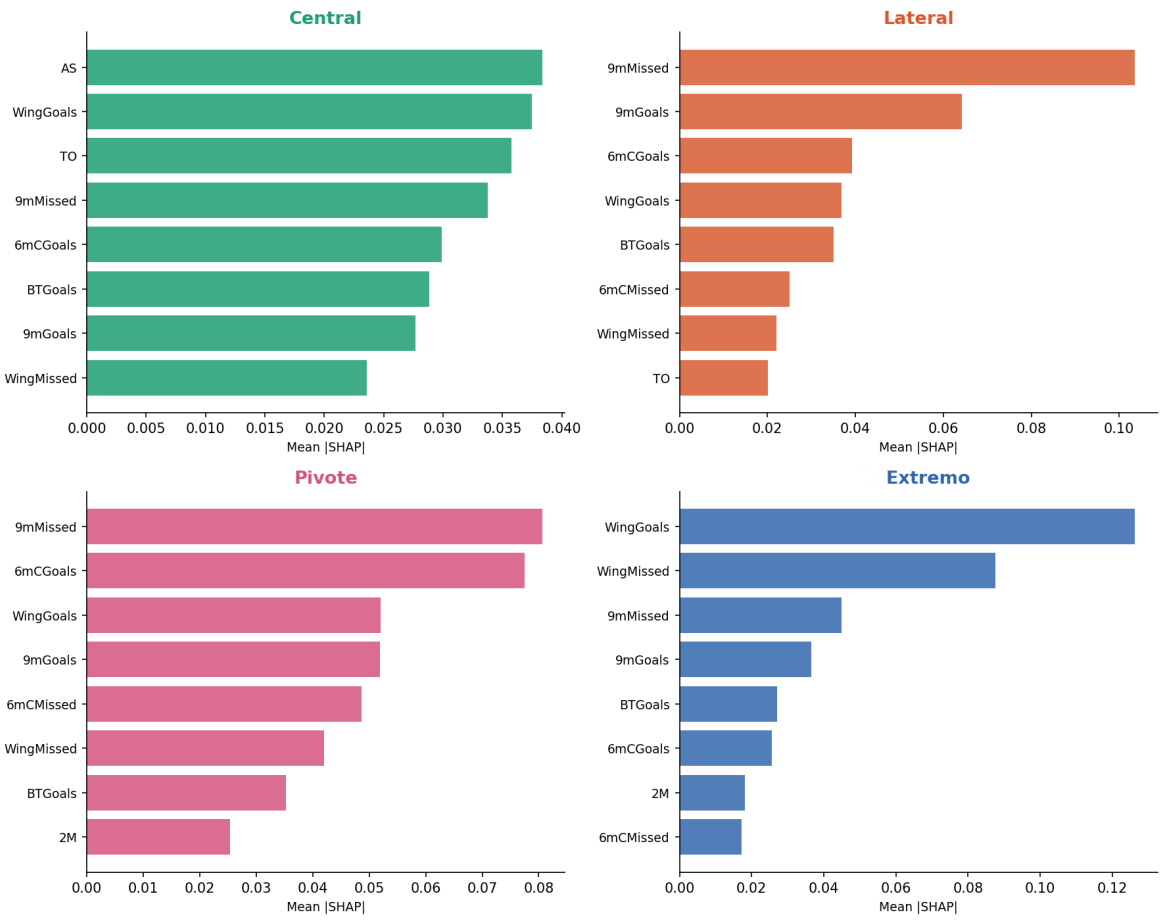


Figura 5.12: Importancia de variables por clase (*Random Forest*) del torneo masculino

5.4. Sprint 4: Comparación entre balonmano masculino y femenino

Una vez completado el análisis de clasificación supervisada sobre el torneo masculino en el *Sprint* anterior, este último *Sprint* tiene como objetivo comparar los resultados obtenidos en ambas modalidades (masculino y femenino) para comprobar si existen diferencias significativas. Se utiliza el torneo femenino de 2024 y el mismo torneo que se ha analizado a lo largo del documento para masculino. Para el torneo femenino, la metodología y los modelos son exactamente los mismos en el masculino, lo que permite atribuir cualquier diferencia a características propias de cada modalidad.

La comparación se divide en tres partes. Primero, se contrastan las métricas de ambos torneos para ver si los modelos clasifican mejor las posiciones en uno u otro. Segundo, se analizan las diferencias en los hiperparámetros seleccionados, ya que la configuración que elige `GridSearchCV` puede reflejar ciertas diferencias en los datos. Por último, se comparan los resultados de *SHAP* para identificar si las variables más discriminantes son las mismas en ambas modalidades o si existen diferencias que apunten a estilos de juego distintos.

5.4.1. Comparación de resultados

La Tabla 5.10 recoge las métricas de EXP2 para los cuatro modelos en ambos torneos. Lo primero que llama la atención es que el torneo femenino obtiene mejores resultados en algunos modelos. *Random Forest* mejora ligeramente (76,0% → 77,5%) y la red neuronal experimenta la mayor mejora (72,0% → 78,9%), mientras que *XGBoost* y *SVM* mantienen un comportamiento muy similar entre torneos. En el torneo masculino el mejor modelo es *Random Forest* (76,0%) mientras que en el femenino es la red neuronal (78,9%) con *Random Forest* muy cerca (77,5%), solo con un fallo menos. Que la red neuronal supere a *Random Forest* en el torneo femenino puede sugerir que los datos femeninos presentan relaciones más complejas y no lineales entre las estadísticas y las posiciones, que la red neuronal es capaz de capturar mejor gracias a su naturaleza.

Analizando la modalidad femenina mediante las matrices de confusión de la Figura 5.13, se observa que los patrones son muy consistentes entre torneos. Para comparar las modalidades, se utiliza *Random Forest* al ser el mejor modelo en la modalidad masculina y estar muy cerca del mejor modelo de la modalidad femenina.

Extremo es la clase mejor clasificada en ambas modalidades en el torneo masculino *Random Forest* clasifica correctamente 16 de 19 extremos y en el femenino sube a 17 de 19. Los

	Masculino		Femenino	
Modelo	**CV Acc.**	**Test Acc.**	**CV Acc.**	**Test Acc.**
Random Forest	0.723	0.760	0.743	0.775
XGBoost	0.753	0.733	0.746	0.732
SVM	0.676	0.640	0.732	0.634
Red Neuronal	0.737	0.720	0.711	0.789

Tabla 5.10: Comparativa de métricas entre torneos

extremos son finalizadores y posiciones dónde prima su efectividad en lanzamientos, son muy determinantes en el balonmano actual de alto rendimiento tanto femenino como masculino.

Lateral también se clasifica con *Random Forest* acertando 22 de 28 laterales en el masculino y 21 de 27 en el femenino. Los laterales en ambos casos son perfiles más goleadores, dónde la diferencia es la física en categoría masculina hay mayor efectividad en lanzamiento exterior, aunque esta tendencia progresivamente está cambian y cada vez hay más jugadoras con mayor efectividad lanzando de fuera.

El *Pivote* funciona de forma similar en ambas modalidades, con tasas de *accuracy* en torno al 85% en la mayoría de los modelos. Es un puesto muy específica donde los roles no varía en femenino y masculino.

El *Central* es la clase más problemática en ambos casos. En el torneo masculino *Random Forest* solo clasifica correctamente 7 de 13 centrales y en el femenino 6 de 12 con los errores repartiéndose principalmente hacia *Lateral* en los dos torneos. Esto confirma que la dificultad del central no es específica de una modalidad sino estructural, su perfil estadístico se solapa con el de los laterales independientemente del género, y durante el juego es habitual que ambas posiciones intercambien roles con frecuencia, lo que dificulta aún más su separación. Son los jugadores más versátiles y sin perfiles claros y definidos. Los hay muy tácticas que solamente hacen jugar al equipo y también muy goleadores. Esta tendencia es similar en balonmano masculino y femenino de alto rendimiento.

En cuanto a los hiperparámetros seleccionados de la Tabla 5.11, las diferencias entre torneos son más reveladoras que las propias métricas. La red neuronal (*MLP*) coincide en arquitectura (512, 256, 128, 64) en ambos torneos, pero el masculino requiere una regularización diez veces mayor ($\alpha = 0.005$ frente a $\alpha = 0.0001$) y una tasa de aprendizaje inicial diez veces más alta (0.005 frente a 0.0005), lo que apunta a que los datos masculinos son estadísticamente más ruidosos y requieren un aprendizaje más agresivo con mayor penalización.

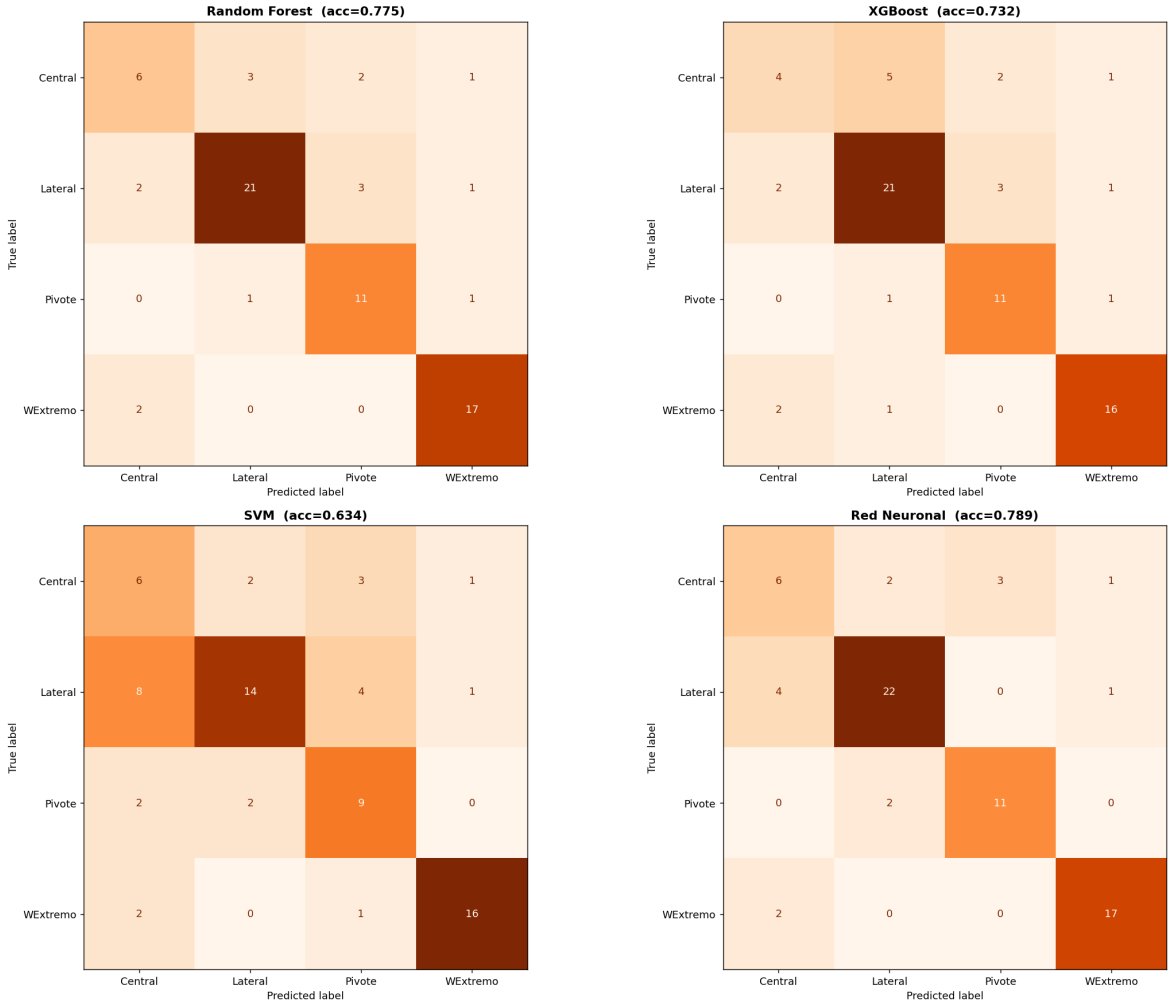


Figura 5.13: Matrices de confusión de los cuatro modelos en la modalidad femenina (4 posiciones)

Modelo	Configuración seleccionada
Random Forest	`n_estimators=50, max_depth=10, max_features=sqrt, min_samples_leaf=1, min_samples_split=5`
XGBoost	`n_estimators=15, max_depth=6, learning_rate=0.5, subsample=0.4, colsample_bytree=0.7, reg_alpha=0.9, min_child_weight=1`
SVM	`C=2.0, gamma=scale, kernel=linear`
Red Neuronal	`hidden_layer_sizes=(512, 256, 128, 64), activation=relu, alpha=0.0001, learning_rate=adaptive, learning_rate_init=0.0005`

Tabla 5.11: Mejores hiperparámetros por modelo del experimento 2 para el torneo femenino

5.4.2. Comparación de importancia de variables *SHAP*

El análisis *SHAP* permite evaluar qué estadísticas son más influyentes para identificar cada posición en cada torneo. Hay que tener en cuenta que en el torneo masculino el mejor modelo es *Random Forest* y en el femenino la red neuronal, lo que introduce una diferencia metodológica. Los valores *SHAP* de *TreeSHAP* y los de la red neuronal no son directamente comparables en magnitud, aunque sí lo son cualitativamente respecto al *ranking* de variables.

A nivel global como se observa en la Figura 5.14, ambos torneos coinciden en que las variables más discriminantes son las relacionadas con el lanzamiento exterior (*9mMissed* y *9mGoals*) y las estadísticas de lanzamiento desde extremos (*WingGoals*, *WingMissed*), junto con los goles de seis metros (*6mCGoals*). Esto confirma que la estructura posicional del balonmano es consistente entre modalidades, las posiciones se diferencian por los mismos tipos de acción con independencia del torneo. Sin embargo, el orden varía en el torneo masculino encabeza *WingGoals*, mientras que en el femenino es *9mMissed*.

En masculino es normal con defensas muy físicas y mayor capacidad de lanzamiento exterior la variable más determinante son los goles desde extremos. Y en femenino dónde se fallan más goles de lanzamiento exterior esta es la variable más importante. El balonmano femenino es más táctico y el masculino más físico.

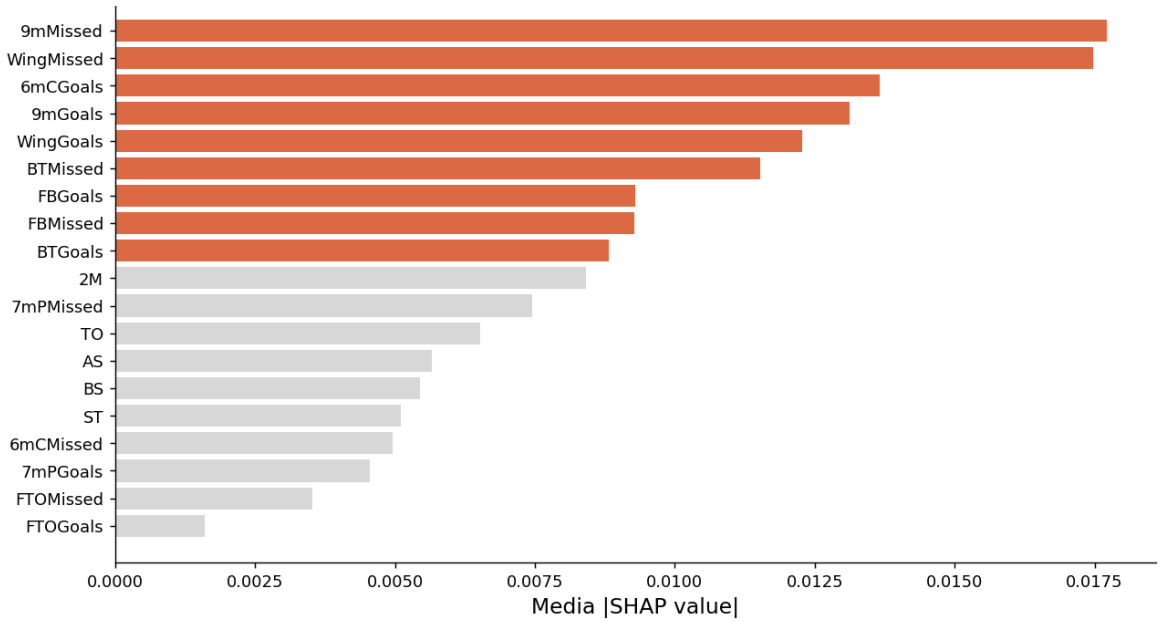


Figura 5.14: Importancia global de las variables del torneo femenino (*MLP*)

Por posiciones como se aprecia en la Figura 5.15, el *Pivote* se identifica en ambos casos principalmente por *6mCGoals* y *9mMissed*. La clase *Extremo* presenta en ambas modalidades una separación muy marcada de *WingGoals* y *WingMissed* sobre el resto. El *Lateral* se apoya en los dos torneos en el lanzamiento exterior (*9mMissed*, *9mGoals*). La mayor diferencia aparece en el *Central*, donde en el torneo masculino lidera *AS* (asistencias), mientras que en el femenino *TO* (pérdidas de balón) encabeza la lista. Además, en la mayoría de casos, los fallos en los lanzamientos son más influyentes en el torneo femenino, pero los aciertos son más influyentes en el torneo masculino. Esto se aprecia comparando ambas gráficas y viendo cómo se invierten las variables entre ambos torneos.

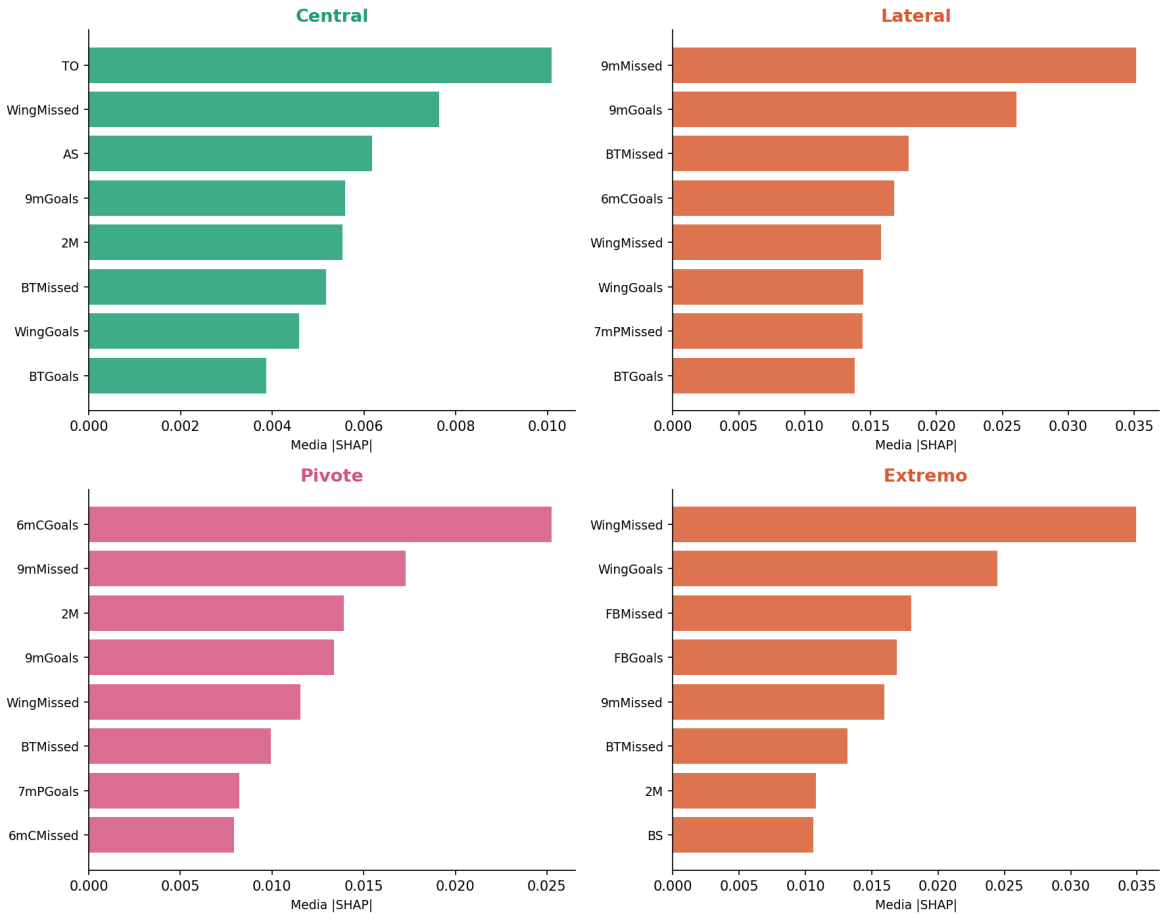


Figura 5.15: Importancia de variables por clase del torneo femenino (*MLP*)

5.4.3. Conclusiones de la comparación

En conjunto, los resultados de ambos torneos son parecidos. Las diferencias más relevantes no están en las métricas finales que son muy parecidas y ese mayor éxito en el femenino se puede deber al tamaño reducido de la muestra, sino en cómo los modelos llegan a esos resultados. El torneo masculino requiere configuraciones más complejas y con mayor regularización, apuntando a que sus datos presentan mayor ruido o fronteras de decisión menos nítidas entre posiciones. El torneo femenino, por su parte, se beneficia más de la red neuronal por poco comparado con *Random Forest*, lo que podría indicar la presencia de relaciones no lineales que la red neuronal consigue capturar adecuadamente.

El *Central* sigue siendo la posición más difícil de clasificar en ambas modalidades, ya que durante el juego es habitual que los jugadores de esta posición intercambien roles con los laterales con frecuencia. Las variables menos relevantes también coinciden en los dos torneos, lo que refuerza la idea de que el conjunto de 19 variables captura bien la información necesaria para determinar la posición de balonmano con independencia del género.

No obstante, sucede un fenómeno interesante al analizar la importancia de las variables por clase. Las variables que representan los lanzamientos acertados son más influyentes en el torneo masculino respecto al femenino, donde ocurre lo contrario, es decir, los fallos tienen una mayor influencia. Esto podría deberse a que el rendimiento ofensivo y la capacidad para materializar las ocasiones de gol constituyen un factor más determinante en el resultado de los encuentros en el torneo masculino. En cambio en el torneo femenino, los errores en el lanzamiento podrían tener un mayor impacto sobre el desarrollo del juego, de modo que minimizar las pérdidas de oportunidades adquiere mayor relevancia.

6. Conclusión y trabajo futuro

Este capítulo presenta las conclusiones obtenidas tras el desarrollo del trabajo, valorando en qué medida se han alcanzado los objetivos planteados y las competencias adquiridas a lo largo del proceso. También, se recogen las principales líneas de trabajo futuro que quedan abiertas a partir de los resultados obtenidos, con el fin de orientar posibles ampliaciones o mejoras de la metodología propuesta

6.1. Objetivos alcanzados

Este trabajo planteó cuatro objetivos específicos que han guiado el desarrollo de cada sprint. A continuación se revisa en qué medida han sido alcanzados.

El primer objetivo consiste en procesar y depurar los datos procedentes de la *API* de la *EHF*. Este objetivo se ha cumplido mediante la obtención de los datos correspondientes a los torneos masculino y femenino del Campeonato de Europa de 2024, la identificación y eliminación de las variables sin capacidad discriminativa, la exclusión de los porteros de este estudio (debido a la ausencia de variables representativas de su rendimiento) y la estandarización de las variables restantes mediante normalización *Z-score*. También, el análisis exploratorio permitió identificar las relaciones más relevantes entre las variables para los *sprints* posteriores. Como resultado se obtuvo un conjunto de datos final compuesto por 371 jugadores de campo masculinos de 19 variables.

El segundo objetivo plantea diseñar una metodología de análisis clúster para agrupar a los jugadores según sus características de rendimiento. Este objetivo se alcanzó tras comparar los algoritmos *K-Means*, *Ward* y *DBSCAN* utilizando tres configuraciones de preprocesamiento (*PCA2*, *PCA3* y *RAW*). Los resultados mostraron que *K-Means* sobre los datos originales (*RAW*) genera buenos grupos y interpretables, diferenciando perfiles en las dis-

tintas posiciones de balonmano y rendimiento. Además, al separar a los jugadores según su rendimiento, el experimento de agrupamiento por cada posición identifica como mejores jugadores aproximadamente el 80% de los jugadores nominados al *MVP* de la *EHF* sin utilizar dicha información durante el entrenamiento, lo que respalda la validez de la metodología propuesta.

El tercer objetivo busca caracterizar los perfiles de los jugadores según su posición mediante técnicas de clasificación supervisada. Para ello, se entrenaron y compararon cuatro modelos (*Random Forest*, *XGBoost*, *SVM* y *MLP*). Los resultados obtenidos indican que la clasificación de las seis posiciones originales no resulta viable con el conjunto de variables disponible. Sin embargo, al agrupar posiciones simétricas en cuatro clases, el rendimiento de los modelos mejora de forma significativa, alcanzando un nivel de discriminación que hace el problema mucho más factible. Además, el análisis *SHAP* ha permitido identificar las variables más influyentes en la clasificación de cada posición, cumpliendo así el objetivo de interpretar qué características son las más relevantes para determinar el rol de un jugador.

El cuarto objetivo se enfoca en comparar los resultados obtenidos en los torneos masculino y femenino aplicando la misma metodología en ambos casos. Los modelos logran obtener un rendimiento similar en ambas competiciones, aunque destaca la red neuronal *MLP* en el torneo femenino, con una exactitud del 78,9%, y el modelo *Random Forest* en el torneo masculino con una exactitud del 76,0%. Además, el análisis *SHAP* muestra que las variables más relevantes son prácticamente las mismas en ambas modalidades, aunque con diferencias en su importancia relativa. Estos resultados confirman que la metodología es consistente y aplicable tanto al balonmano masculino como al femenino. Las variables identificadas como más determinantes para cada posición coinciden con el conocimiento táctico habitual del balonmano (por ejemplo, los goles de extremo para caracterizar a la posición de extremo o los lanzamientos de 6 metros para el Pivote), lo que respalda que los perfiles obtenidos son coherentes con lo que cabría esperar desde la experiencia de entrenadores y analistas del deporte

6.2. Competencias adquiridas

A lo largo de este trabajo, se han adquirido las siguientes competencias:

- **CP01. Integrar tecnologías, aplicaciones, servicios y sistemas propios de la Ingeniería Informática, con carácter generalista, y en contextos más amplios y multidisciplinares.** Esta competencia se ha desarrollado mediante la integración de diferentes tecnologías en un mismo proyecto como la obtención de datos desde la *API* de la *EHF*, su

procesamiento y análisis con *Python* y sus librerías, y la documentación del trabajo en LaTeX. Además, el proyecto combina conocimientos de Ingeniería Informática, ciencia de datos y análisis del rendimiento deportivo en balonmano.

- **CP05. Aplicar métodos matemáticos, estadísticos y de inteligencia artificial para modelar, diseñar y desarrollar aplicaciones, servicios, sistemas inteligentes y sistemas basados en el conocimiento.** Esta es la competencia principal del trabajo. Se han aplicado técnicas de reducción de dimensionalidad, *clustering* y clasificación supervisada, junto con procedimientos de optimización y validación de modelos. Además, el uso de *SHAP* ha permitido interpretar las predicciones e identificar las variables más relevantes para caracterizar la posición de juego de los jugadores. Con todo ello, se ha diseñado una metodología para la limpieza de datos y el entrenamiento de los modelos, definiendo las etapas de preprocesado, selección de variables y configuración del flujo de experimentación para asegurar el resto de tareas.
- **CP07. Realizar, presentar y defender un ejercicio original (TFM) consistente en un proyecto integral de Ingeniería Informática de naturaleza profesional que sintetice las competencias adquiridas.** Esta competencia queda reflejada en el desarrollo completo del proyecto, desde la definición del problema hasta la evaluación de los resultados y su documentación. El uso de datos reales de la EHF y la aplicación de técnicas actuales de análisis de datos e inteligencia artificial aportan un carácter profesional al trabajo y muestran la integración de los conocimientos adquiridos durante el máster.

6.3. Trabajo futuro

Los resultados obtenidos abren varias líneas de trabajo para ampliar y mejorar la metodología propuesta. En primer lugar, sería interesante incorporar datos de más competiciones y temporadas para entrenar modelos más robustos y analizar la evolución de los perfiles de rendimiento a lo largo del tiempo. También sería interesante enriquecer el conjunto de variables con estadísticas más detalladas, como datos por partido o el tiempo de juego de cada jugador, lo que permitiría obtener perfiles más precisos.

El enfoque de agrupamiento desarrollado podría evolucionar hacia una herramienta de *scouting* capaz de identificar automáticamente perfiles de jugadores y detectar talentos durante una competición, proporcionando información útil para entrenadores y cuerpos técnicos. Por ello, sería ideal diseñar una aplicación que utilice los modelos entrenados para ofrecer una caracterización de los jugadores de un torneo en curso, asignando a cada jugador un

perfil de rendimiento más cercano, comparándolo con los jugadores de élite de su posición e indicando en qué estadísticas destaca o se aleja de la media del grupo. Esta herramienta podría integrarse en el flujo de trabajo de un cuerpo técnico durante una competición, facilitando la toma de decisiones sobre rivales o la detección de talentos emergentes.

A. Anexo 1

A.1. Software del proyecto

A.1.1. Python

Python es un lenguaje de programación de propósito general ampliamente adoptado en el ámbito de la ciencia de datos y el aprendizaje automático. Se ha utilizado la versión 3.11.9 como lenguaje principal del proyecto por su ecosistema de librerías especializadas y la facilidad con la que permite combinar análisis exploratorio, modelado y visualización en un mismo entorno.

A.1.2. Jupyter Notebook

Jupyter Notebook es un entorno de desarrollo interactivo que permite estructurar el código en celdas ejecutables de forma independiente. Se ha utilizado como entorno principal para el desarrollo de los experimentos, facilitando la exploración iterativa de los datos y la documentación progresiva de los resultados.

A.1.3. Visual Studio Code

Visual Studio Code es un editor de código desarrollado por *Microsoft*. Se ha utilizado para la edición de código *Python*.

A.1.4. Librerías de Python

Las principales librerías de *Python* empleadas a lo largo del proyecto son **pandas** y **numpy** para la manipulación de datos, **scikit-learn** para el preprocesamiento, los algoritmos de clus-

tering y los modelos de clasificación supervisada, **scipy** para el *clustering jerárquico Ward*, **xgboost** para el algoritmo XGBoost, **shap** para el análisis de importancia de variables, **matplotlib** y **seaborn** para las visualizaciones, y **requests** para la obtención de datos desde la API de la EHF. La Tabla A.1 contiene las versiones de las líbrerías

Librería	Versión
numpy	2.4.3
pandas	3.0.1
scipy	1.17.1
matplotlib	3.10.8
seaborn	0.13.2
scikit-learn	1.8.0
xgboost	2.1.3
shap	0.46.0

Tabla A.1: Librerías de Python utilizadas en el desarrollo del proyecto

A.1.5. Microsoft Teams

Microsoft Teams es una aplicación desarrollada por *Microsoft* que facilita la comunicación y la colaboración en equipos de trabajo. Se ha utilizado como canal principal de comunicación con los tutores del proyecto para la celebración de las reuniones semanales de seguimiento de cada *sprint*.

A.2. Hardware del proyecto

Todo el desarrollo y la experimentación del proyecto se han llevado a cabo en un ordenador portátil cuyas especificaciones se recogen en la Tabla A.2.

Tabla A.2: Especificaciones del equipo utilizado en el proyecto.

Componente	Especificación
Procesador	Intel Core i7
Memoria RAM	16 GB
Tarjeta gráfica	Intel Iris Xe Graphics (integrada)
Sistema operativo	Windows 10

Referencia bibliográfica

[1] GeeksforGeeks, “K-means vs k-means++ clustering algorithm,” 2025.

[2] J. Barrios, “La matriz de confusión y sus métricas,” 2023. Consultado: 15-Jun-2026.

[3] Scikit-learn Developers, “Cross-validation: evaluating estimator performance,” 2025. Documentación oficial de Scikit-learn. Consultado: 15-Jun-2026.

[4] G. A. Betancourt, “Las mÁquinas de soporte vectorial (svms),” *Dialnet*, 2015. Consultado: 15-Jun-2026.

[5] Pumbaa80 and R. agains, “Campo de balonmano.svg,” 2008. Wikimedia Commons. Consultado: 15-Jun-2026.

[6] J. A. Lopez-Gomez, F. P. Romero, and E. Angulo, “A feature-weighting approach using metaheuristic algorithms to evaluate the performance of handball goalkeepers,” *IEEE Access*, 2022.

[7] J. A. Lopez-Gomez, F. P. Romero, and E. Angulo, “Bio-inspired algorithms for the characterization of excellent performance in handball players: A data-driven methodology,” *Expert Systems With Applications*, 2025.

[8] C. M. P. Pertuz, *Aprendizaje automático y profundo en Python*. Ra-Ma, 2020.

[9] J. L. González, “Tipos de aprendizaje automático,” 2020. Consultado: 12-Jun-2026.

[10] J. . Gallardo San Salvador, “Técnicas de análisis cluster,” 2013. Material docente. Consultado: 12-Jun-2026.

[11] A. M. Ikotun, A. E. Ezugwu, L. Abualigah, B. Abuhaija, and J. Heming, “K-means clustering algorithms: A comprehensive review, variants analysis, and advances in the era of big data,” *Information Sciences*, vol. 622, pp. 178–210, 2023.

[12] J. . Gallardo San Salvador, “Métodos jerárquicos de análisis cluster,” 2011. Material docente. Consultado: 13-Jun-2026.

[13] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, “A density-based algorithm for discovering clusters in large spatial databases with noise,” in *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)*, pp. 226–231, AAAI Press, 1996.

[14] J. C. Alonso Cifuentes, M. F. Largo Liévano, and C. C. Hoyos Bermeo, *Una introducción a los modelos de Clústering empleando R*. Cali, Colombia: Editorial Universidad Icesi, 2025.

[15] IBM, “What is supervised learning?,” 2025. Consultado: 15-Jun-2026.

[16] IBM, “¿qué es una matriz de confusión?,” 2025. Consultado: 15-Jun-2026.

[17] R. A. Irizarry, “Validación cruzada,” 2024. Capítulo 29 de Introducción a la Ciencia de Datos.

[18] IBM, “¿qué es random forest?,” 2025. Consultado: 15-Jun-2026.

[19] XGBoost Developers, “Xgboost documentation,” 2026. Documentación oficial de XGBoost. Consultado: 15-Jun-2026.

[20] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, 1986.

[21] E. D. Aguilera, “Comparación de clasificadores de género: Redes neuronales mlp y teoría de la información –itl–,” *Dialnet*, 2010. Consultado: 15-Jun-2026.

[22] SHAP Developers, “Shap documentation: Overviews,” 2026.

[23] European Handball Federation, “Rules of the game.” `https://www.eurohandball.com`, 2024.

[24] G. Wijngaard, “Clustering soccer players: investigating unsupervised learning on player positions,” B.S. thesis, Utrech University, 2020.

[25] J. Castellano, S. Bellmunt, R. Resta, R. Lopez del Campo, and D. Casamichana, "Multivariate analysis of teams' physical performances in official football matches in laliga 2023-24," *Biology of Sport*, 2025.

[26] B. Spencer, S. Morgan, J. Zeleznikow, S. Robertson, and W. Bulldogs, "Clustering team profiles in the australian football league using performance indicators," in *Proceedings of the 13th Australasian conference on mathematics and computers in sport, Melbourne*, 2016.

[27] R. Patel, *Clustering professional basketball players by performance*. University of California, Los Angeles, 2017.

[28] S. Zhang, A. Lorenzo, M.-A. Gómez, N. Mateus, B. Gonçalves, and J. Sampaio, "Clustering performances in the nba according to players anthropometric attributes and playing experience," *International Journal of Performance Analysis in Sport*, 2018.

[29] P. Gupta, "Categorizing playing styles of ice hockey players using gaussian mixture model," 2025.

[30] Z. Shelly, R. F. Burch, W. Tian, L. Strawderman, A. Piroli, and C. Bichey, "Using k-means clustering to create training groups for elite american football student-athletes based on game demands," *International Journal of Kinesiology and Sports Science*, 2020.

[31] I. J. Bautista, I. J. Chirosa, J. E. Robinson, R. van der Tillaar, L. J. Chirosa, and I. M. Martín, "A new physical performance classification system for elite handball players: cluster analysis," *Journal of Human Kinetics*, vol. 51, 2016.

[32] M. Gómez-López, J. A. Merino-Barrero, D. Manzano Sánchez, and A. Valenzuela, "A cluster analysis of high-performance handball players perceived motivational climate: Implications on motivation, implicit beliefs of ability and intention to be physically active," *International Journal of Sports Science Coaching*, 08 2019.

[33] P. Meletakos, K. Noutsos, A. Paulo, A. Papavasileiou, and S. Drikos, "Identifying performance indicators for success in the european men's handball championships," *Journal of Physical Education and Sport*, 2025.

[34] Z. Petrovszki, O. Czimbalmos, V. Gal, G. Korosi, E. Nagy, R. Mikulan, and G. Horvath, "Age- and post-based complex analyses of heart rate variability in young male handball players for potential prevention of overload-induced injuries," *Physical Activity and Health*, Feb. 2025.

[35] L. Vogel and T. Schack, “Cognitive representations of handball tactic actions in athletes—the function of expertise and age,” *PLOS ONE*, May 2023.

[36] J. Sindik and A.-M. Bauer Čuk, “Psychological characteristics and traits in male handball players – optimism, athlete engagement and mental energy,” *Sport SPA*, 2015.

[37] Y. Yu, “Analysis and prediction of CBA player position data characteristics based on machine learning,” *American Journal of Applied Mathematics and Statistics*, 2024.

[38] A. T. andChristodoulos Efstathiades, “Towards predicting basketball player positions with transformative insights,” *Machine Learning and Knowledge Extraction*, 2025.

[39] F. H. Yagin, U. Hasan, F. Clemente, . Eken, G. Badicu, and M. Gülü, “Using machine learning to determine the positions of professional soccer players in terms of biomechanical variables,” *Proceedings of the Institution of Mechanical Engineers Part P Journal of Sports Engineering and Technology*, vol. 239, 09 2023.

[40] A. Enaganti and G. Pappas, “Optimizing nfl draft selections with machine learning classification,” 2025.

[41] M. Oytun, C. Tinazci, B. Sekeroglu, and H. U. Acikada, Caner Yavuz, “Performance prediction and evaluation in female handball players using machine learning models,” *IEEE Access*, 2020.

[42] H. Wagner, M. Hinz, K. Melcher, V. Radic, and J. Uhrmeister, “The playerscore: A systematic game observation tool to determine individual player performance in team handball competition,” *Applied Sciences*, 2023.

[43] Florian, C. Felice, and Ley, “Predicting handball matches with machine learning and statistically estimated team strengths,” *Sports Analytics*, 2025.

[44] M. Estrada Velasco, J. Núñez Villacis, P. Saltos Chávez, and W. Cunuhay Cuchipe, “Revisión sistemática de la metodología scrum para el desarrollo de software,” *Dominio de las Ciencias*, vol. 7, no. 4, pp. 434–447, 2021.

[45] scikit-learn developers, “Kmeans clustering,” *scikit-learn documentation*, 2026. Accessed: 2026-06-03.

[46] scikit-learn developers, “Agglomerative clustering,” *scikit-learn documentation*, 2026. Accessed: 2026-06-03.

[47] IBM, “¿qué es el análisis de componentes principales (pca)?,” 2025. Consultado: 27-Jun-2026.

[48] European Handball Federation, “EHF Excellence Awards 2024,” 2024. Consultado: junio de 2025.

[49] Scikit-learn Developers, “sklearn.pipeline.pipeline,” 2025. Documentación oficial de Scikit-learn. Consultado: 18-Jun-2026.

[50] Scikit-learn Developers, “sklearn.model_selection.gridsearchcv,” 2025. Documentación oficial de Scikit-learn.